Početna strana

Zadatak rada

Sadržaj

1. Uvod ... 1
1.1 Definisanje problema i cilj rada ... 1
1.2 Pregled stanja u oblasti ... 2
1.3 Značaj i primena sistema za prepoznavanje saobraćajnih znakova ... 3
2. Saobraćajni znakovi i korišćeni skup podataka ... 4
2.1 Podela saobraćajnih znakova ... 4
2.1.1 Znakovi opasnosti ... 5
2.1.2 Znakovi izrečih naredbi ... 5
2.1.3 Znakovi obaveštenja ... 5
2.2 “STOP” znak i znakovi ograničenja brzine ... 6
2.2.1 Znak “STOP” ... 6
2.2.2 Znakovi ograničenja brzine ... 7
2.3 Skup podataka GTSRB ... 8
3. Teorijske osnove ... 9
3.1 Prostori boja ... 9
3.1.1 RGB prostor boja ... 9
3.1.2 HSV prostor boja ... 10
3.1.3 Konverzija iz RGB u HSV prostor boja ... 10
3.2 Segmentacija slike ... 11
3.2.1 Segmentacija zasnovana na boji ... 11
3.2.2 Segmentacija crvene boje ... 12
3.2.3 Prednosti i mane segmentacije zasnovane na boji ... 13
3.3 Razvoj regiona ... 13
3.3.1 Tačke semena ... 13
3.3.2 Proširivanje regiona ... 14
3.3.3 Kriterijum zaustavljanja algoritma ... 15
3.3.4 Prednosti i mane razvoja regiona ... 15
3.4 Analiza oblika ... 16
3.4.1 Konture i konveksni omotač ... 16

3.4.2 Momenti i afini momenti invarijanti ... 16
3.4.3 Eliptičnost i oktagonalnost ... 17
3.4.4 Kružnost ... 18
3.4.5 Aproksimacija konture i broj temena ... 18
3.4.6 Odnos stranica i rotirani granični pravougaonik ... 18
3.4.7 Solidnost ... 19
3.4.8 Fitovanje elipse ... 19
3.4.9 Kombinovanje geometrijskih krakteristika ... 20
3.5 Konvolutivne neuronske mreže ... 20
3.5.1 Konvolutivni sloj ... 21
3.5.2 ReLU aktivaciona funkcija ... 22
3.5.3 Normalizacija paketića podataka ... 23
3.5.4 *Max Pooling* ... 23
3.5.5 *Dropout* ... 24
3.5.6 *GlobalAveragePooling* i potpuno povezani slojevi ... 24
3.5.7 Softmax funkcija ... 25
3.5.8 Funkcija gubitka i proces obučavanja mreže ... 25
3.5.9 Optimizacioni algoritam Adam ... 26
3.5.10 Augmentacija podataka ... 26
4. Implementacija sistema za prepoznavanje saobraćajnih znakova ... 27
4.1 Korišćene tehnologije ... 27
4.1.1 *Python* ... 27
4.1.2 *OpenCV* ... 28
4.1.3 *TensorFlow i Keras* ... 28
4.2 Arhitektura sistema ... 29
4.3 Segmentacija po boji ... 31
4.3.1 Konverzija slike u HSV prostor ... 31
4.3.2 Formiranje maske crvene boje ... 32
4.3.3 Formiranje slike na osnovu semena ... 33
4.3.4 Razvoj regiona ... 35
4.4 Analiza oblika ... 37

4.4.1 Izdvajanje kontura i konveksnog omotača 37
4.4.2 Izračunavanje geometrijskih karakteristika 38
4.4.3 Prepoznavanje kružnih i osmougaonih kandidata 40
4.5 Izdvajanje regiona od interesa 42
4.5.1 Određivanje graničnog pravougaonika 42
4.5.2 Proširivanje regiona od interesa 43
4.5.3 Izdvajanje regiona iz originalne slike 43
4.5.4 Skaliranje izdvojenog regiona od interesa 44
4.5.5 Konverzija redosleda kanala 45
4.5.6 Formiranje odgovarajućeg ulaza za konvolutivnu neuronsku mrežu 45
4.6 Priprema podataka za proces obučavanja neuronske mreže 46
4.6.1 Organizacija skupa podataka 47
4.6.2 Ujednačavanje dimenzija slika 47
4.6.3 Podela podataka na terning i validacioni skup 48
4.6.4 Grupisanje podataka u paketiće 48
4.6.5 Optimizacija učitavanja podataka 48
4.6.6 Augmentacija podataka 49
4.6.7 Normalizacija vrednosti piksela 49
4.6.8 Algoritam pripreme podataka 50
4.7 Konvolutivna neuronska mreža 50
4.7.1 Konvolutivni deo mreže 51
4.7.2 Klasifikacioni deo mreže 51
4.7.3 Arhitektura čitave mreže 53
4.7.4 Kompilacija modela 54
4.7.5 Parametri procesa obučavanja 54
4.7.6 Kontrola procesa obučavanja 54
4.7.7 Obučavanje i čuvanje modela 55
4.7.8 Algoritam formiranja i obučavanja konvolutivne neuronske mreže 55
4.8 Klasifikacije detektovanih znakova 57
4.8.1 Učitavanje obučenog modela 57
4.8.2 Prosleđivanje regiona od interesa neuronskoj mreži 57

4.8.3 Određivanje dodeljene klase 57
4.8.4 Prag sigurnosti klasifikacije 58
4.8.5 Prikaz konačnog rezultata 58
4.8.6 Čitav postupak klasifikacije 60
5. Rezultati sistema za prepoznavanje znakova 61
5.1 Rezultati segmentacije po boji 61
5.2 Rezultati analize oblika 64
5.3 Rezultati obučavanja konvolutivne neuronske mreže 66
5.4 Rezultati čitavog sistema 68
6. Zaključak 72
Literatura 74
Izvor slika 75

1. Uvod

1.1 Definisanje problema i cilj rada

Jedan od važnijih elemenata saobraćaja predstavljaju saobraćajni znakovi, koji za cilj imaju da učesnicima saobraćanja daju informacije o stanju na putu, zabranama i pravilima ponašanja na putu. S povećanjem primene modernih inteligentnih tehnologija u automobilskoj industriji takođe se javlja i potreba za nekim načinom automatskog prepoznavanja saobraćajnih znakova.

Problem prepoznavanja saobraćajnih znakova zasniva se na konceptima detekcije i klasifikacije. Detekcija predstavlja pronalaženje dela slike na kom se nalazi saobraćajni znak, dok klasifikacija predstavlja određivanje konkretnog tipa znaka. U realnim uslovima upotreba ovakvih sistema može imati poteškoća zbog osvetljenja, prisustva senke, promeni perspektive, zaklanjanja znakova drugim objektima, pojava objekata sličnih boja u blizini znakova.

Sistem koji je razvijen u okviru ovog rada se fokusira isključivo na prepoznavanje znakova ograničenja brzine i znaka „STOP“. Ovaj sistem za detekciju koristi kombinaciju metoda detekcije po boji i po obliku, gde se prvo na slici izdvajaju regioni određene boje, a zatim se analiziraju njihove geometrijske karakteristike kako bi se izdvojili kružni i osmougaoni oblici. Nakon detekcije ovih regiona oni se dalje za klasifikaciju prosleđuju neuronskoj mreži koja kao izlaz daje konačan tip znaka. Ovakav sistem se može nazvati hibridnim sistemom koji kombinuje metode kompjuterske vizije i mašinskog učenja.

Obučavanje i validacija modela mašinskog učenja u okviru ovog rada rađeno je na skupu podataka GTSRB (*German Traffic Sign Recognition Benchmark*) koji uključuje velik broj različitih znakova slikanih u različitim uslovima.

Cilj ovog master rada je razvoj i analiza sistema za automatsko prepoznavanje saobraćajnih znakova zasnovan na kombinaciji metoda za detekciju i klasifikaciju sa fokusom na prepoznavanje znakova ograničenja brzine i znaka „STOP“.

1.2 Pregled stanja u oblasti

Značaj prepoznavanja saobraćajnih znakova ogleda se u razvoju inteligentnih transportnih sistema i autonomnih vozila. Ovo je jedna od bitnijih oblasti kompjuterskog vida jer pouzdanim prepoznavanjem saobraćajnih znakova omogućava vozilima pravilnu interpretaciju ograničenja brzine, upozorenja, stanja na putu, zabrane, čime se učesnicima u saobraćaju smanjuje rizik od nezgoda i povećava bezbednost na putu [1].

Savremeni sistemi za prepoznavanje znakova prema novijim istraživanjima sastoje se iz nekoliko delova: pretprocesiranje slike, izdvajanje regiona interesa i klasifikacije. U zavisnosti od metode klasifikacije koja se koristi, u metode za prepoznavanje znakova se mogu svrstati tradicionalne metode mašinskog učenja i metode dubokog učenja [1].

Tradicionalne metode mašinskog učenja zahtevaju ručno definisanje karakteristika slika, poput boja, oblika i tekstura. Često korišćeni algoritmi u ovoj grupi su: SVM (*Support Vector Machine*), k-najbližih suseda (*KNN*) i stabla odlučivanja. Prednost ovih metoda je manja složenost, kao i lakše i brže obučavanje modela, dok se najveći nedostatak ogleda u slabijoj mogućnosti generalizacije na kompleksnijim skupovima podataka [1].

Velika popularnost neuronskih mreža poslednjih godina dovela je do njihove upotrebe i u ovoj oblasti. Najprimenjeniji tip neuronskih mreža unutar ove oblasti su konvolutivne neuronske mreže. Nasuprot tradicionalnim metodama, kod neuronskih mreža se automatski vrši izdvajanje karakteristika iz ulaznih podataka, čime se gubi potreba za ručnim definisanjem osobina slike [1].

Takođe, pored razvoja samih algoritama, velik doprinos u ovoj oblasti imaju i javno dostupni skupovi podataka koji objedinjuju velik broj slika saobraćajnih znakova različitih tipova. Među ovim javno dostupnim skupima podataka najviše se izdvajaju: GTSRB (*German Traffic Sign Recognition Benchmark*), BTSD (*Belgian Traffic Sign Dataset*) i TSRD (*Chinese Traffic Sign Dataset*). Ovi skupovi takođe služe i kao standard za poređenje performansi različitih metoda [1].

Nasuprot uloženim naporima u istraživanja unutar ove oblasti, prepoznavanje saobraćajnih znakova i dalje predstavlja jedan jako kompleksan izazov zbog varijacije u osvetljenju, prisustva senki, refleksija, različitih pozadina, različitih vremenskih uslova i razlika između saobraćajnih znakova u različitim državama. Iz tih razloga sistemi koji se razvijaju u okviru savremenih istraživanja su jako robusni i kombinuju metode obrade slike sa metodama dubokog učenja [1].

U okviru ovog rada implementiran je i prikazan upravo takav sistem. On uključuje segmentaciju slike u HSV prostoru boja, izdvajanje geometrijskih karakteristika znakova i klasifikaciju koristeći konvolutivnu neuronsku mrežu sa ciljem prepoznavanja određenih tipova znakova za ograničenje brzine i znaka “STOP”.

1.3 Značaj i primena sistema za prepoznavanje saobraćajnih znakova

Značaj sistema za prepoznavanje saobraćajnih znakova najviše se ogleda u unapređenju bezbednosti u saobraćaju, kao i razvoju inteligentnih transportnih sistema. Sa porastom broja učesnika u saobraćaju i potrebom za automatizaciju saobraćaja, javlja se sve veća potreba za sistemima koji mogu brzo i bezbedno da prepoznaju saobraćajne znakove i samim tim daju bitne informacije vozaču ili upravljačkom sistemu vozila.

Jedna od najvažnijih primena ovih sistema je u sklopu naprednih sistema pružanja podrške vozaču (*Advanced Driver Assistance Systems - ADAS*). Ovi sistemi su vrlo bitni u okviru saobraćaja jer njihovo korišćenje vozaču pruža više informacija o njegovom trenutnom stanju u saobraćaju i samim tim smanjuje broj nezgoda u saobraćaju [1].

Ovi sistemi igraju jako veliku ulogu za razvoj autonomnih vozila. Prepoznavanje saobraćajnih znakova u realnom vremenu autonomnim vozilima omogućava da svoje ponašanje prilagode uslovima na putu. Iz tih razloga razvoj i unapređivanje algoritama za detekciju i klasifikaciju znakova igra bitnu ulogu u oblasti autonomnih vozila [1].

Sistemi za automatsko prepoznavanje saobraćajnih znakova našli su primenu i u održavanju saobraćajne infrastructure. Putem kamera na vozilima moguće je identifikovati položaj znakova, provera da li oni imaju neka oštećenja ili da li nedostaje znakova, čime se kasnije mogu ažurirati odgovarajuće baze podataka.

Jasno definisane kategorije i pristup velikom broju podataka omogućavaju da sistemi za prepoznavanje znakova budu jako pogodni za implementaciju i testiranje algoritama iz oblasti računarskog vida i mašinskog učenja.

2. Saobraćajni znakovi i korišćeni skup podataka

Jedan od osnovnih elemenata saobraćajne infrastrukture su saobraćajni znakovi. Njihova uloga u saobraćaju je da učesnicima saobraćaja signaliziraju informacije o pravilima, ograničenjima, opasnostima i stanju na putu, čime doprinose regulaciji saobraćaja i bezbednosti svih učesnika saobraćaja.

Za razvoj sistema za prepoznavanje saobraćajnih znakova jako je bitno poznavati njihove vizuelne karakteristike i način podele. Pored samih znakova za razvoj ovih sistema veliku ulogu igraju dostupni skupovi podataka koji služe za treniranje modela za klasifikaciju znakova.

U okviru ovog poglavlja biće prikazana podela saobraćajnih znakova prema Pravilniku o saobraćajnoj signalizaciji Republike Srbije, kao i skup podataka korišćen za izradu sistema unutar ovog rada.

2.1 Podela saobraćajnih znakova

Prema pravilniku o saobraćajnoj signalizaciji Republike Srbije, znakovi se mogu podeliti u tri osnovne kategorije [2]:

- Znakovi opasnosti;
- Znakovi izrečitih naredbi;
- Znakovi obaveštenja.

Na slici 2.1 Prikazan je primer nekih od znakova koji pripadaju gore navedenim kategorijama.



Slika 2.1 Primeri saobraćajnih znakova prema pravilniku o saobraćajnoj signalizaciji Republike Srbije.

2.1.1 Znakovi opasnosti

Znakovi opasnosti upozoravaju vozače da je u njihovoj neposrednoj blizini ili na putu opasnost. Njihova uloga je da vozačima na vreme ukažu na opasnost čime bi oni mogli da prilagode brzinu i način vožnje [2].

U ovu grupu znakova spadaju znakovi koji upozoravaju na oštre krivine, pešačke prelaze, raskrsnice, suženje kolovoza, radove na putu i druge moguće opasnosti. Znakovi koji se ubrajaju u ovu kategoriju su najčešće trougaonog oblika sa crvenim obodom i belom pozadinom [2].

2.1.2 Znakovi izrečih naredbi

Znakovi izrečitih naredbi određuju zabrane, ograničenja i obaveze koje vozači trebaju da poštuju. U ovu grupu znakova svrstavaju se znakovi zabrane i ograničenja, kao i znakovi obaveze [2].

Primeri ovih znakova uključuju znak "STOP", znakovi ograničenja brzine, zabrana preticanja, zabrana skretanja i znakovi koji signaliziraju obavezan smer kretanja. Znakovi zabrane karakteristični su po kružnom obliku sa crvenim obodom, dok je znak "STOP" izuzetak jer je osmougaonog oblika [2].

S obzirom da će se u ovom radu najviše govoriti o znakovima koji pripadaju ovoj kategoriji, biće obraćeno više pažnje na njihove karakteristike, boje i oblik.

2.1.3 Znakovi obaveštenja

Znakovi obaveštenja vozačima daju informaciju o pravcu kretanja, mestima za parkiranje, turističkim destinacijama, udaljenosti, benzinskim stanicama i drugim objektima od značaja [2].

Ova kategorija znakova uključuje znakove različitih oblika i boja, najčešće su to pravougaoni ili kvadratni znakovi plave ili zelene boje sa belom pozadinom. Njihova funkcija je da vozačima olakšaju snalaženje u prostoru kako bi na vreme doneli željene odluke [2].

Pored ovih znakova mogu biti postavljene i dopunske table koje predstavljaju deo samog znaka i daju dodatne informacije o njegovom značenju [2].

2.2 “STOP” znak i znakovi ograničenja brzine

Sistem za prepoznavanje znakova koji je razvijen unutar ovog rada fokusira se na prepoznavanje „STOP“ znaka i znakova za ograničenje brzine. Ovi znakovi su izabrani za prepoznavanje iz razloga jer su oni jedni od najvažnijih znakova izrečitih naredbi i njihovim korektnim prepoznavanjem došlo bi do povećanja bezbednosti u saobraćaju.

2.2.1 Znak “STOP”

Znak “STOP” ima za cilj da vozaču unutar saobraćaja kaže da zaustavi vozilo ispred raskrsnice ili drugog mesta kod kojeg je postavljen i da nakon što utvrdi bezbednost učesnika u saobraćaju nastavi da se kreće [2].

Ovaj znak se izdvaja od svih ostalih znakova po svom karakterističnom osmougaonom obliku, što ga čini jako pogodnim za metode prepoznavanja na osnovu oblika. Pored oblika karakteriše ga i crvena pozadina sa belim tekstom. Na slici 2.2 nalazi se primer izgleda znaka „STOP“ [2].



Slika 2.2 Znaka “STOP”

2.2.2 Znakovi ograničenja brzine

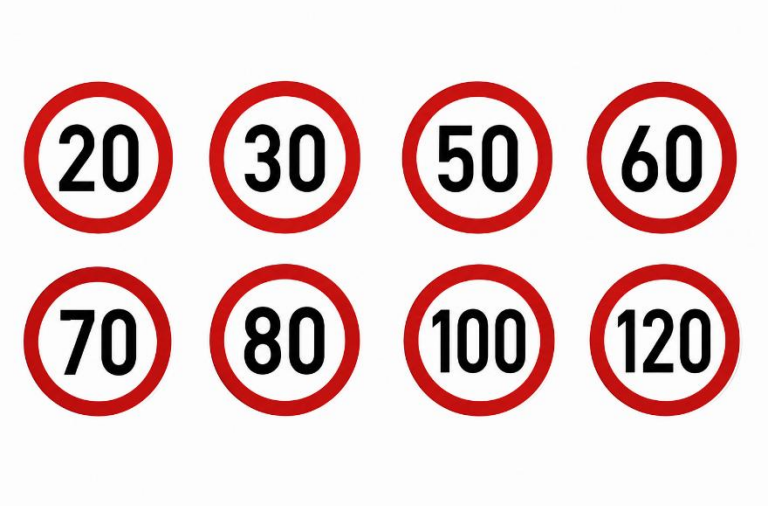
Znakovi ograničenja brzine služe tome da bi odredili najveću dozvoljenu brzinu kretanja vozila na odgovarajućem delu puta. Njihova najvažnija uloga je da povećaju bezbednost u saobraćaju tako što ukazuju vozačima na prilagođavanje brzine uslovima na putu, gustini u saobraćaju i karakteristikama okruženja [2].

Ovi znakovi karakteristični su po kružnom obliku, crvenom obodu i beloj pozadini, kao i vrednosti ograničenja prikazanom crnim brojevima. Zbog sličnosti između znakova ograničenja brzine njihovo prepoznavanje predstavlja složeniji problem od samo detekcije oblika znaka [2].

Sistem koji je izrađen unutar ovog rada može da prepozna sledeće znakove ograničenja brzine:

- 20 km/h
- 30 km/h
- 50 km/h
- 60 km/h
- 70 km/h
- 80 km/h
- 100 km/h
- 120 km/h

Na slici 2.3 dati su primer izgleda znakova ograničenja brzine na koje se fokusira ovaj rad.



Slika 2.3 Znakovi ograničenja brzine

Sa slike iznad vidi se da je jedina razlika između samih znakova numerička oznaka ograničenja brzine, zbog čega se unutar sistema nakon izdvajanja regiona koji sadrže krugove crvene boje, dati regioni prosleđuje konvolutivnoj neuronskoj mreži za dalje prepoznavanje odgovarajućih znakova.

2.3 Skup podataka GTSRB

Za obučavanje i testiranje modela mašinskog učenja za prepoznavanje saobraćajnih znakova u ovom radu korišćen je skup podataka GTSRB (*German Traffic Sign Recognition Benchmark*). Ovo je jedan od najpoznatijih i najkorišćenijih skupova podataka u oblasti prepoznavanja saobraćajnih znakova. Razvijen je od strane Instituta za neuroinformatiku Univerziteta Ruhr u Bohumu u okviru takmičenja organizovanog na konferenciji IJCNN 2011[4].

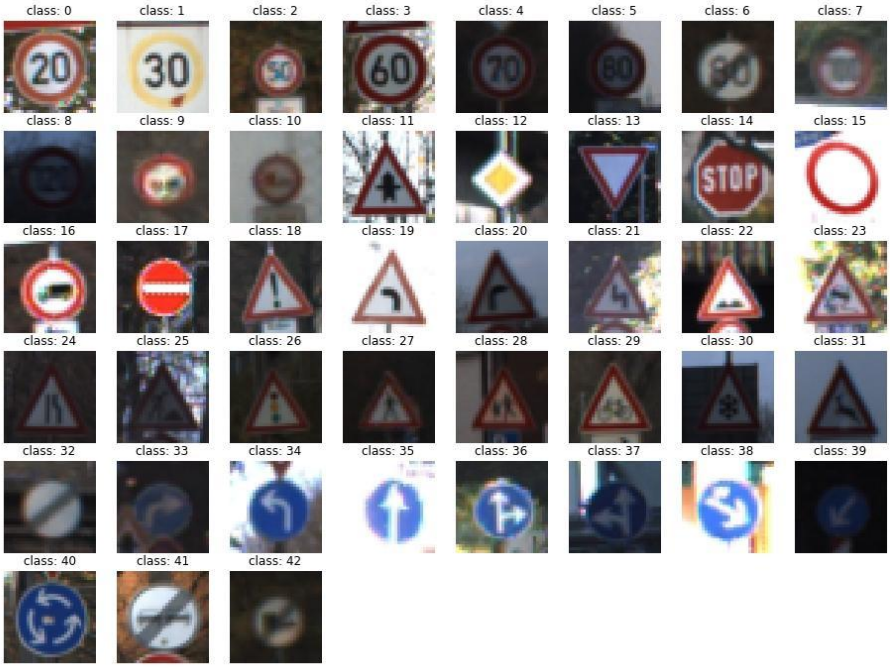
GTSRB je namenjen za rešavanje problema višeklasne klasifikacije pojedinačnih saobraćajnih znakova. Ovaj skup podataka sadrži preko 50000 slika podeljenih u 43 različite klase znakova. Ove slike prikupljene su u realnim uslovima u saobraćaju i obuhvataju slike pod različitim uglovima, sa različitim osvetljenjem, slikanim u različitim vremenskim uslovima[4].

Struktura ovog skupa podataka organizovana je tako da svaka klasa znakova ima svoj direktorijum koji sadrži tridesetak slika tog znaka slikanih iz različitih uglova i iz različitih perspektiva [4].

Slike unutar samog skupa podataka nisu standardne veličine već variraju od dimenzija 15 x 15 do 250 x 250 piksela. Svaka slika sadrži saobraćajni znak i dodatan prostor oko njega[4].

Iako sam skup podataka sadrži 43 klase, za izradu ovog rada korišćen je podskup podataka koji sadrže slike znaka „STOP“ i znakova ograničenja brzine koji su navedeni u prethodnom potpoglavlju.

Na slici 2.4 dat je primer nekih slika koje pripadaju ovom skupu podataka.



Slika 2.4 Primer slika iz GTSRB skupa podataka

3. Teorijske osnove

3.1 Prostori boja

U okviru kompjuterskog vida boja predstavlja jednu od najvažnijih karakteristika digitalnih slika. Ona predstavlja jako dobru osnovu za prepoznavanje objekata na slikama, ali sama po sebi nije dovoljna u većini slučajeva, kao što je slučaj i kod prepoznavanja znakova, gde nije dovoljno prepoznati samo boju da bi se odredio konkretan znak. Postoji dosta različitih modela kojima se boja može predstaviti u digitalnim sistemima, među kojima su jedni od najprimenjenijih RGB i HSV prostor boja [3].

Ovaj rad obuhvata korišćenje oba sistema boja, gde se ulazna slika predstavlja u RGB prostoru, dok se HSV prostor koristi za segmentaciju saobraćajnih znakova na osnovu njihovih odgovarajućih boja.

3.1.1 RGB prostor boja

RGB (*Red, Green, Blue*) prostor boja predstavlja jednu boju kao kombinaciju njene crvene, zelene i plave komponente. Svaka boja u RGB prostoru može se dobiti kombinacijom ove tri komponente. Zapis boje u RGB prostoru dat je ispod [3]:

(R, G, B)

gde R određuje intenzitet crvene boje, G određuje intezitet zelene boje, a B intenzitet plave boje. Ove komponente na standardnim slikama imaju vrednosti između 0 i 255. Tako da unutar računara jedan piksel se može predstaviti korišćenjem 3 bajta memorije. Jarko crvena boja u ovom sistemu boja bi imala sledeći zapis:

$$(R, G, B) = (255, 0, 0)$$

RGB prostor boja se koristi u okviru digitalnih kamera, monitora i drugih uređaja koji služe za prikazivanje slike. Međutim, najveći nedostatak ovog sistema je što su informacije o boji i osvetljenju međusobno povezane, što i nije najpogodnije za segmentaciju objekata u uslovima promenjivog osvetljenja [3].

3.1.2 HSV prostor boja

HSV (*Hue, Saturation, Value*) prostor boja razdvaja informaciju o boji od informacije od osvetljenosti. Svaka boja unutar ovog prostora predstavlja se pomoću naredne tri komponente [3]:

- *Hue* (H) – predstavlja nijansu boje
- *Saturation* (S) – predstavlja zasićenost boje
- *Value* (V) – predstavlja osvetljenost boje

Hue komponenta predstavlja položaj boje na kružnom spektru i izražava se uglom od 0° do 360° dok se ostale dve komponente izražavaju u procentima. Na primer jarko crvena boja bi u ovom prostoru boja imala sledeći zapis:

$$(\mathrm{H}, \mathrm{S}, \mathrm{V}) = (0°, 100\%, 100\%)$$

što znači da je nijansa crvena, zasićenost je maksimalna i osvetljenje je maksimalno.

Za razliku od RGB prostora, HSV prostor omogućava jednostavnije izdvajanje objekata na osnovu njihove boje i zbog toga se često koristi u sistemima za obradu slike i u računarskom vidu [3].

3.1.3 Konverzija iz RGB u HSV prostor boja

S obzirom da većina uređaja predstavlja slike u RGB prostoru boja, za obradu slika jako je važno poznavati način konverzije iz RGB prostora u HSV prostor boja. Neka su R, G i B normalizovane vrednosti crvene, zelene i plave komponente u opsegu [0, 1].

Za konverziju najpre je potrebno odrediti maksimalnu, minimalnu vrednost i njihovu razliku na sledeći način[3]:

$$C_{max} = \max(R, G, B)$$

$$C_{min} = \min(R, G, B)$$

$$\Delta = C_{max} - C_{min}$$

Dalje na osnovu ovoga komponente H, S i V možemo izračunati na sledeći način:

$$H = \begin{cases} 0°, & \Delta = 0 \\ 60°(\frac{G-B}{\Delta} \ mod \ 6), & C_{max} = R \\ 60°(\frac{B-R}{\Delta} + 2), & C_{max} = G \\ 60°(\frac{R-G}{\Delta} + 4), & C_{max} = B \end{cases}$$

$$S = \begin{cases} 0, & C_{max} = 0 \\ \frac{\Delta}{C_{max}}, & C_{max} \neq 0 \end{cases}$$

$$V = C_{max}$$

3.2 Segmentacija slike

Segmentacija slike predstavlja postupak podele slike na veći broj međusobno povezanih regiona u cilju izdvajanja regiona od interesa. U računarskom vidu segmentacija slike predstavlja jedan od najvažnijih koraka obrade slike, jer se njenim pojednostavljivanjem smanjuje broj podataka potrebnih za obradu u narednim fazama sistema [3].

Cilj same segmentacije je grupisanje piksela koji imaju slične karakteristike, kao što su boja, tekstura, oblik ili intenzitet. Segmenti dobijeni ovim izdvajanjem mogu biti pojedinačni objekti ili njihovi delovi koji se dalje koriste u analizi i klasifikaciji [3].

Postoji veliki broj karakteristika na osnovu kojih može da se vrši segmentacija slika, a neke od metoda segmentacije su:

- Segmentacija zasnovana na intenzitetu
- Segmentacija zasnovana na boji
- Segmentacija zasnovana na teksturi
- Segmentacija zasnovana na ivicama

U okviru ovog rada korišćena je metoda segmentacije zasnovana na boji jer je takav način segmentacije najpogodniji za razlikovanje saobraćajnih znakova od okoline.

3.2.1 Segmentacija zasnovana na boji

Segmentacija zasnovana na boji je metoda segmentacije koja izdvaja regione slike koji pripadaju određenom opsegu boja. Ovaj pristup je pogodan za prepoznavanje saobraćajnih znakova zato što se za izradu znakova koriste standardizovane boje, kao što su crvena, plava, žuta i bela [3].

Segmentacija se u HSV prostoru boje vrši analizom komponenti *Hue, Saturation* i *Value.* Algoritam segmentacije poredi svaki piksel slike sa unapred definisanim opsezima komponenti, tako da svaki piksel koji zadovoljava date uslove pripada delu posmatranog objekta. Sam piksel pripada odgovarajućoj boji ako zadovoljava naredni uslov:

$$H_{min} \leq H \leq H_{max}$$
$$S_{min} \leq S \leq S_{max}$$
$$V_{min} \leq V \leq V_{max}$$

Čime se na osnovu ovih uslova formira binarna maska:

$$M(x,y) = \begin{cases} 1, & ako\ piskel\ zadovoljava\ uslove \\ 0, & u\ suprotnom \end{cases}$$

Pikseli u novoformiranoj maski koji imaju vrednost 1 pripadaju posmatranoj boji, dok pikseli koji imaju vrednost 0 sačinjavaju pozadinu.

3.2.2 Segmentacija crvene boje

Vrsta segmentacije koja je korišćena unutar ovog rada jeste segmentacija na osnovu crvene boje, pošto znak „STOP“ i znakovi ograničenja brzine poseduju karakterističan crveni obod.

Za razliku od svih ostalih boja, segmentaciju objekata crvene boje unutar HSV prostora boja karakterišu dve granice, jer se jedan deo crvene boje nalazi na početku spektra, dok se drugi deo nalazi na njegovom kraju. Zato se segmentacija crvene boje vrši korišćenjem narednih uslova:

$$0^\circ \leq H \leq H1$$

i

$$H2 \leq H \leq 360^\circ$$

Kao i za H komponentu, tako se i za S i V komponente postavljaju ograničenja kako bi se eliminisali pikseli koji pripadaju senkama, refleksijama i objektima sličnih boja.

3.2.3 Prednosti i mane segmentacije zasnovane na boji

Prednosti segmentacije zasnovane na boji su:

- jednostavna implementacija
- zahteva manje resursa računara
- brzo izvršavanje
- efikasno izdvajanje objekata odgovarajućih boja

Mane ove metode su:

- osetljivost na promene osvetljenja
- nedostaci izazvani pojavom senki i refleksija
- zavisnost od konkretno odabranih uslova

Zbog navedenih nedostataka ova metoda se u ovom radu kombinuje sa još par metoda obrade slike kako bi se povećala pouzdanost sistema za prepoznavanje znakova.

3.3 Razvoj regiona

Razvoj regiona je metod segmentacije slike koji se zasniva na regionima, čiji je cilj da izdvoji povezane oblasti slike koji imaju slične karakteristike. Ova metoda zansiva se na postepenom proširavanju početnog regiona dodavanjem novih susednih piksela koji zadovoljavaju unapred definisane uslove [3].

Metoda razvoja regiona je pogodna za izdvajanje objekata pravilnog oblika sa slike zbog toga što za razliku od metoda koje uzimaju svaki pojedinačni piksel, ova metoda uzima u obzir i prostornu povezanost piksela. Algoritam razvoja regiona čine sledeći koraci [3]:

- Izbor početnih tačaka – semena (*eng. seed*)
- Definisanje kriterijuma sličnosti
- Ispitivanje susednih piksela
- Proširivanje regiona
- Zaustavljanje algoritma kada više nema piksela koji zadovoljavaju zadate uslove

3.3.1 Tačke semena

Početni korak algoritma razvoja regiona je odabir početnih tačaka, odnosno semena. Semena su oni pikseli za koje se unapred pretpostavlja da pripadaju objektu koji je potrebno izdvojiti[3].

Semena u okviru sistema razvijenog u ovom radu dobijena su primenom segmentacije po boji u HSV prostoru. Pikseli koji zadovoljavaju početne uslove crvene boje izabrani su kao kandidati za proširivanje regiona.

Neka je seme definisano koordinatama:

$$S = (x_0, y_0)$$

Odakle algoritam započinje proširivanje regiona.

3.3.2 Proširivanje regiona

Nakon izbora semena, algoritam ispituje susedne piksele. Najčešće se govori o dva tipa susedstva: četvorosusedstvo i osmosusedstvo [3].

Kod četvorosusedstva piksel sa koordinatama (x, y) povezan je sa pikselima koji imaju naredne koordinate:

$$(\mathrm{x}-1, \mathrm{y})$$

$$(\mathrm{x}+1, \mathrm{y})$$

$$(\mathrm{x}, \mathrm{y}-1)$$

$$(\mathrm{x}, \mathrm{y}+1)$$

Dok se kod osmosusedstva u obzir još uzimaju i susedi koji se nalaze dijagonalno od posmatranog piksela čije su koordinate:

$$(\mathrm{x}-1, \mathrm{y}-1)$$

$$(\mathrm{x}-1, \mathrm{y}+1)$$

$$(\mathrm{x}+1, \mathrm{y}-1)$$

$$(\mathrm{x}+1, \mathrm{y}+1)$$

pri čemu se piksel ubraja u region, ukoliko zadovoljava kriterijum sličnosti:

$$|I(x,y) - I_s| < T$$

gde su:

- I(x, y) – vrednost posmatranog piksela
- I_s - vrednost semena
- T – unapred definisan prag

Ukoliko je ovaj uslov zadovoljen za posmatrani piksel, uslov se dalje ispituje za susede tog piksela [3].

3.3.3 Kriterijum zaustavljanja algoritma

Algoritam se završava ukoliko ne postoji ni jedan susedni piksel posmatranog piksela koji zadovoljava definisani kriterijum sličnosti.

Odnosno, algoritam se zaustavlja ako je sledeći uslov ispunjen za sve susedne piksele:

$$|I(x,y) - I_s| \geq T$$

Nakon završetka samog algoritma, dobija se region koji predstavlja potencijalni objekat na slici.

3.3.4 Prednosti i mane razvoja regiona

Prednosti ove metode su:

- Jednostavna implementacija
- Uzima u obzir i prostornu povezanost piksela
- Mogućnost izdvajanja objekata nepravilnog oblika

Mane ove metode su:

- Zavisnost od izbora semena
- Osetljivost na šum
- Zavisnost od izbora praga T
- Mogućnost prevelikog ili premalog proširivanja regiona

Zbog navedenih mana, metoda razvoja regiona se u sistemu koji je razvijen u okviru ovog rada kombinuje sa metodom segmentacije slike po boji i analizom oblika, čime se povećava tačnost sistema.

3.4 Analiza oblika

Analiza oblika obuhvata postupak izdvajanja i opisivanja geometrijskih karakteristika objekata na slici. Cilj analize oblika je da izdvoji karakteristike pomoću kojih se mogu razlikovati objekti različitih oblika. Ova metoda u obzir uzima i geometrijske osobine objekta, kao što su broj temena, kružnost, eliptičnost i sličnost sa unapred definisanim geometrijskim figurama [5].

Pošto sistem koji je razvijen u okviru ovog rada prepoznaje znak „STOP“ i znakove ograničenja brzine, od posebnog značaja su osmougaoni i kružni, odnosno eliptični oblici.

3.4.1 Konture i konveksni omotač

Kontura predstavlja skup tačaka koje opisuju granicu datog objekta na slici. Ona se definiše na sledeći način:

$$C = \{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$$

Gde parovi (x_i, y_i) predstavljaju konkretne koordinate tačaka koje pripadaju datoj konturi[3].

Na osnovu same konture moguće je odrediti osnovne geometrijske karakteristike nekog objekta, kao što su obim i površina. Površina regiona A opisuje njegovu veličinu, dok obim P opisuje njegove granice. Ove osnovne geometrijske karakteristike su bitne jer se koriste za izračunavanje složenijih mera oblika, poput kružnosti[3].

Ako se govori o realnim slikama, konture na njima mogu imati nepravilnosti nastale usled šuma, pojave senki, oštećenja znakova ili nepotpune segmentacije. Iz ovih razloga često se koristi konveksni omotač (*eng. convex hull*). Konveksni omotač je najmanji konveksni region koji sadrži sve tačke posmatranog objekta[3].

3.4.2 Momenti i afini momenti invarijanti

Momenti slike predstavljaju numeričke karakteristike kojima je moguće opisati geometrijsku raspodelu piksela unutar posmatranog objekta[6].

Centralni moment reda $p+q$ moguće je izračunati na sledeći način

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q f(x, y)$$

gde $\bar{x}$ i $\bar{y}$ predstavljaju koordinate težišta objekta, a f(x, y) vrednost piksela[2].

Da bi se neki oblik opisao koristi se prvi afini moment invarijanti

$$I_1 = \frac{\mu_{20}\mu_{02} - \mu_{11}^2}{\mu_{00}^4}$$

koje su definisali Flusser i Suk[6].

Prednost ove vrste invarijanti je u tome što je smanjena zavisnost od geometrijskih transformacija, poput translacije, rotacije ili skaliranja oblika[6]. Ovo je jako bitna karakteristika u primeni kod saobraćajnih znakova, jer se oni mogu pojaviti na različitim mestima slike i pod različitim uglovima.

3.4.3 Eliptičnost i oktagonalnost

Na osnovu prvog afinog momenta invarijanti mogu se definisati mere sličnosti sa određenim geometrijskim oblicima[5].

Jedna od takvih mera sličnosti je eliptičnost. Eliptičnost predstavlja meru sličnosti objekta idealnoj elipsi. Idealna elipsa ima vrednost prvog afinog momenta invarijanti:

$$I_E = \frac{1}{16\pi^2}$$

Eliptičnost ima vrednost u intervalu [0, 1], gde ukoliko joj je vrednost 1, onda dati objekat se idealno poklapa sa elipsom[5].

Eliptičnost je izuzetno važna geometrijska karakteristika jer se usled perspektive kružni znak može pojaviti i kao elipsa.

Druga mera sličnosti bitna za prepoznavanje znakova je oktagonalnost. Oktagonalnost predstavlja meru sličnosti objekta idealnom osmouglu. Idealni osmougao ima vrednost prvog afinog momenta invarijanti:

$$I_E = \frac{1}{15.932\pi^2}$$

Kao i eliptičnost i ova mera može imati vrednost u intervalu [0, 1], gde ukoliko joj je vrednost 1, onda dati objekat se idealno poklapa sa osmouglom[5].

Pošto su vrednosti za idealnu elipsu i osmougao jako bliske, eliptičnost i oktagonalnost se u praksi kombinuju sa više dodatnih geometrijskih karakteristika.

3.4.4 Kružnost

Kružnost predstavlja meru sličnosti objekta idealnom krugu i definiše se sledećim izrazom:

$$C = \frac{4\pi A}{P^2}$$

gde je P obim objekta, a A površina[3].

Idealan krug ima vrednost kružnosti C = 1, pri čemu kada se oblik udaljava od idealnog kruga ili njegova kontura postaje nepravilna, vrednost kružnosti se smanjuje.

Kružnost je jako korisna mera za detekciju kružnih znakova, ali sama po sebi nije dovoljna za razlikovanje svih oblika.

3.4.5 Aproksimacija konture i broj temena

Kontura objekta može sadržati veći broj tačaka, zbog čega se često vrši njena aproksimacija mnogouglom. Cilj aproksimacije je da se početna kontura zameni manjim brojem karakterističnih tačaka s tim da se očuva osnovni oblik objekta. Broj temena dobijenog mnogougla predstavlja jednu od važnijih karakteristika za određivanje oblika objekta [3].

U realnim uslovim broj temena nekog objekta ne mora da se idealno poklapa sa njegovim teorijskim brojem temena zbog šuma, rezolucije slike i perspektivne deformacije [3].

3.4.6 Odnos stranica i rotirani granični pravougaonik

Još jedan način da se oblik geometrijski opiše je pomoću pravougaonika koji ga obuhvata. Ako su *w* i *h,* širina i visina pravougaonika, onda se odnos stranica može definisati na sledeći način:

$$AR = \frac{w}{h}$$

Objekti koji su približno simetrični imaj vrednost odnosa stranica približno 1.

Pošto običan granični pravougaonik zavisi od orijentacije objekta, koristi se i rotirani granični pravougaonik, za koji se posmatra odnos:

$$AR_r = \frac{min(w_r, h_r)}{max(w_r, h_r)}$$

Ove dve karakteristike omogućavaju razlikovanje između kompaktnih i izduženih objekata [3].

3.4.7 Solidnost

Solidnost predstavlja meru kompaktnosti koja definiše odnos površine regiona i njegovog konveksnog omotača.

$$S_o = \frac{A}{A_{CH}}$$

gde je A površina objekta, a A_{CH} površina konveksnog omotača [15].

Kompaktni objekti imaju vrednost solidnosti 1, dok za objekte koji imaju velika udubljenja ili nepravilnosti vrednost solidnosti smanjuje.

3.4.8 Fitovanje elipse

Fitovanje elipse predstavlja postupak nalaženja elipse koja najbolje aproksimira određenu konturu[3]. Elipsa koja se dobija ovim postupkom opisana je velikom i malom osom, dok se njen odnos definiše kao

$$R_E = \frac{a_{min}}{a_{max}}$$

Elipsa kao geometrijski oblik definisana je sa dve međusobno normalne ose koje prolaze kroz njen centar i to su velika i mala osa.

Velika osa predstavlja najdužu duž koja prolazi kroz centar elipse i povezuje dve naspramne strane na njenoj konturi. Mala osa je normalna na veliku osu i takođe prolazi kroz centar elipse i predstavlja najkraću duž koja povezuje dve naspramne tačke elipse.

Vrednost odnosa za idealan krug je 1, dok se on smanjuje povećavanjem deformacije.

Pored odnosa osa, može se posmatrati i odnos površine regiona i površine fitovane elipse kako bi se procenilo koliko dobro elipsa opisuje posmatrani objekat.

3.4.9 Kombinovanje geometrijskih karakteristika

Na osnovu jedne karakteristike nije moguće pouzdano određivanje oblika objekta. Pored toga pojedinačne karakteristike mogu imati jako slične vrednosti za različite oblike ili mogu biti osetljive na šum i perspektivu. Iz tih razlog se kombinuju sve do sada navedene karakteristike:

- Afini momenti invarijanti
- Eliptičnost
- Oktagonalnost
- Kružnost
- Broj temena
- Odnos stranica
- Solidnost
- Karakteristike fitovane elipse

kako bi dale kompletnu i pouzdanu sliku o obliku posmatranog objekta.

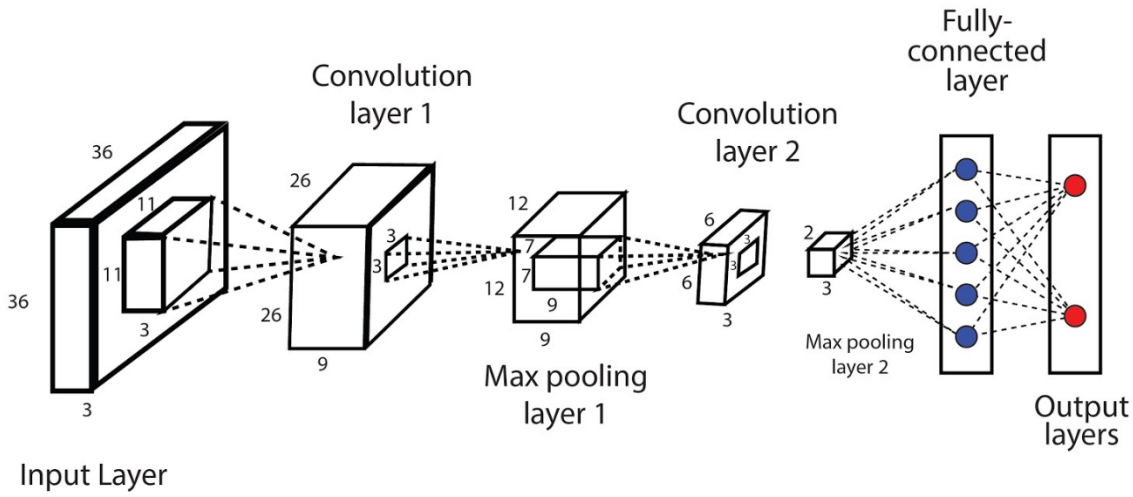
3.5 Konvolutivne neuronske mreže

Konvolutivne neuronske mreže (*CNN*) su vrsta neuronskih mreža koje su prilagođene za obradu podataka koji imaju prostornu strukturu, među koje spadaju i digitalne slike. Za razliku od standardnih metoda koje se koriste u oblasti mašinskog učenja za koje je potrebno unapred definisati karakteristike objekta, konvolutivne neuronske mreže ove karakteristike koje su važne za razlikovanje različitih klasa uče tokom procesa treniranja [8].

Slike su u neuronskoj mreži predstavljene kao višedimenzionalni niz numeričkih vrednosti. Ukoliko je ulazna slika u RGB formatu onda se ona predstavlja pomoću tri kanala, tako da odgovaraju crvenoj, zelenoj i plavoj komponenti. Konvolutivna mreža podatke u ovom formatu obrađuje duž niz slojeva tako da se u početnim slojevima izdvajaju jednostavne karakteristike, a u dubljim slojevima formiraju složenije reprezentacije potrebne za klasifikaciju[8].

Arhitektura tipične konvolutivne neuronske mreže za klasifikaciju slika sastoji se iz konvolutivnih slojeva, aktivacionih funkcija, slojeva za smanjenje dimenzionalnosti i na kraju potpuno povezanog sloja za klasifikaciju. Pored ovih slojeva mogu se naći i slojevi koji služe za normalizaciju i regularizaciju kako bi se smanjila mogućnost prilagođavanju podacima za obučavanje [8].

Na slici 3.1 dat je primer arhitekture konvolutivne neuronske mreže koja kao ulaz uzima sliku formata 36x36 piksela.



Slika 3.1 Primer arhitekture konvolutivne neuronske mreže

3.5.1 Konvolutivni sloj

Konvolutivni sloj predstavlja jedan od najvažnijih elemenata konvolutivne neuronske mreže i njegova uloga je da vrši konvoluciju slike, odnosno izdvajanje lokalnih karakteristika slike primenom matrica koje se nazivaju filteri ili kerneli [8].

Filter se pomera preko ulazne slike i na svakoj poziciji računa kombinaciju vrednosti piksela koji se nalaze unutar njegovog lokalnog dela slike. Za dvodimenzionalni slučaj ovaj postupak se može predstaviti narednim izrazom:

$$Y(i,j) = \sum_m \sum_n X(i + m, j + n) K(m,n) + b$$

gde su:

- X – ulazna mapa karakteristika
- K – filter

- b – *bias*
- Y – izlazna mapa karakteristika

Same vrednosti filtera ne određuju se ručno, već se tokom obučavanja mreže i one uče. Različiti filteri mogu delovati na različite lokalne regione slike, kao što su ivice, prelazi intenziteta, linije i druge karakteristične šare. Složenije karakteristike dobijaju se kombinacijom izlaza prethodnih slojeva konvolucije [8].

Jedna od najznačajnijih osobina konvolucije jeste deljenje težina. Isti filter se prevlači kroz različite delove slike, zbog čega nije neophodno učiti poseban skup parametara za svaku poziciju. Time se broj parametara značajno smanjuje u odnosu na potpuno povezanu neuronsku mrežu koja bi povezivala svaki piksel sa svakim neuronom [8].

Značajni parametri za konvolutivni sloj su: veličina filtera, korak pomeranja (*eng. stride*) i dopunjavanje ivica (*eng. padding*).

3.5.2 ReLU aktivaciona funkcija

Nakon završetka konvolucije primenjuje se aktivaciona funkcija. Njena uloga je da u model uvede nelinearnost čime bi omogućila učenje složenijih odnosa između ulaznih podataka [8].

Jedna od najčešće korišćenih aktivacionih funkcija kod konvolutivnih neuronskih mreža jeste ReLU (eng. *Rectified Linear Unit*) i ona se definiše na sledeći način:

$$f(x) = max(0, x)$$

Ova funkcija za negativne ulaze daje 0, dok pozitivne ulaze samo propušta.

ReLU aktivaciona funkcija je jako pogodna za neuronske mreže jer se jednostavno izračunava i ima dobre osobine prilikom postupka optimizacije. U arhitekturi konvolutivne neuronske mreže korišćene u okviru ovog rada ReLU aktivaciona funkcija se koristi za svaki konvolutivni sloj i potpuno povezani sloj [8].

3.5.3 Normalizacija paketića podataka

U procesu obučavanja neuronske mreže vrednosti na izlazima pojedinih slojeva mogu se menjati sa promenom parametara prethodnog sloja. Normalizacija paketića podataka predstavlja postupak koji normalizuje aktivacije unutar mreže koristeći statističke osobine samih paketića podataka. Ova metoda se koristi sa ciljem da olakša i ubrza obučavanje neuronskih mreža [9].

Za paketić podataka najpre se određuje njegova srednja vrednost:

$$\mu_B = \frac{1}{m}\sum_{i=1}^{m} x_i$$

kao i disperzija:

$$\sigma_B^2 = \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_B)^2.$$

Dok se normalizacija vrši korišćenjem naredne formule:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}$$

gde ε predstavlja mali pozitivan broj kojim se sprečava deljenje sa nulom.

Zatim se normalizovana vrednost može skalirati i pomeriti pomoću parametra koji mreža uči:

$$y_i = \gamma\hat{x}_i + \beta$$

Na ovaj način neuronska mreža zadržava mogućnost da tokom obučavanja odredi odgovarajuću raspodelu aktivacija. Normalizacija paketića podataka se primenjuje u svakom konvolutivnom bloku mreže trenirane za izradu ovog rada.

3.5.4 *Max Pooling*

Nakon izdvajanja karakteristika konvolucijom često se primenjuje postupak objedinjavanja (*eng. pooling*) kojim se smanjuje prostorna dimenzionalnost mape karakteristika. Ovim postupkom se smanjuje količina podataka i zahtevi izračunavanja narednih slojeva [8].

Najčešće korišćen metod objedinjavanja je takozvani *MaxPooling*. Ovim postupkom ulazna mapa deli se na regione, tako da se kao rezultat svakog regiona zadržava njegova najveća vrednost [8].

Na primer ako region mape izgleda ovako:

$$\begin{bmatrix} 2 & 5 \\ 1 & 3 \end{bmatrix}$$

rezultat postupka *MaxPooling*-a bio bi [5].

Na taj način ostavlja se izražen odgovor na određenu karakteristiku, dok se dimenzionalnost same mape smanjuje. Ovaj postupak takođe doprinosi i tome da mala pomeranja elemenata na slici imaju manji uticaj na izlaz neuronske mreže [8].

3.5.5 *Dropout*

Neuronske mreže sa velikim brojem parametara mogu da se previše prilagode trening podacima. Ova pojava naziva se preprilagođavanje (*eng. overfitting*) i može dovesti do toga da model na kraju ima slabije sposobnosti klasifikacije podataka koje ranije nisu viđene.

Jedna od metoda regularizacije koja sprečava dolazak do pojave preprilagođavanja je upravo *Dropout*. Ova metoda zasniva se na nasumičnom gašenju određenog broja neurona i njihovih veza. Ovim se smanjuje zavisnost između pojedinih međusobno povezanih neurona i na taj način se podstiče mreža da uči robusnije prezentacije [10].

U modelu treniranom u okviru ovog rada Dropout slojevi se nalaze na kraju svakog konvolutivnog bloka.

3.5.6 *GlobalAveragePooling* i potpuno povezani slojevi

Nakon završetka konvolucije višedimenzionalne mape karakteristika potrebno je pretvoriti u takav oblik da bude pogodan za dalju klasifikaciju.

Jedan od načina da se to učini je postupak *GlobalAveragePooling*-a. Kod ovog postupka za svaku mapu karakteristika se određuje prosečna vrednost njenih prostornih elemenata [8].

Ako je mapa karakteristika X_k dimenzija H x W, rezultat za k-tu mapu se može zapisati na sledeći način:

$$g_k = \frac{1}{HW} \sum_{i=1}^{H} \sum_{j=1}^{W} X_k(i,j)$$

Na ovaj način se svaka mapa karakteristika svodi na jednu vrednost, čime se znatno smanjuje količina podataka koji se prosleđuju za dalju klasifikaciju.

Nakon ovog sloja koristi se potpuno povezani sloj. U ovom sloju svaki izlazni neuron je povezan sa svim izlaznim neuronima prethodnog sloja. Osnovni zadatak ovog sloja se može predstaviti sledećom formulom:

$$y = f(Wx + b)$$

gde su W matrica težina, b pristrasnost, a f aktivaciona funkcija.

3.5.7 Softmax funkcija

Ukoliko mreža treba da izabere jednu od više od 2 klase, onda je u pitanju problem višeklasne klasifikacije. U tim slučajevima za izlazne slojeve neuronske mreže često se koristi *softmax* aktivaciona funkcija koja izlazne vrednosti mreže pretvara u raspodelu u intervalu [0, 1] [8].

Za N klasa *softmax* funkcija za *i*-tu klasu se može definisati na sledeći način:

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^{N} e^{z_j}}$$

gde je z_i izlazna vrednost mreže za *i*-tu klasu. Dobijene vrednosti moraju zadovoljavati naredni uslov:

$$\sum_{i=1}^{N} p_i = 1$$

Klasa za koju je vrednost *softmax* funkcije najveća se uzima kao predviđena klasa.

3.5.8 Funkcija gubitka i proces obučavanja mreže

U procesu obučavanja mreže važan korak je određivanje razlike između izlaza i stvarne klase. U ovu svrhu se koristi funkcija gubitka (*eng. loss function*).

Jedna od jako često korišćenih funkcija gubitaka za višeklasnu klasifikaciju jeste kategorička unakrstna entropija. Ako je tačna klasa označena sa y, a mreža joj pridružuje vrednost p_y, funkcija gubitka se može zapisati kao [8]:

$$L = -log(p_y)$$

Cilj procesa obučavanja se može definisati onda kao pronalaženje onih parametara za koje funkcija gubitka ima najmanju vrednost, odnosno minimizacija funkcije gubitka. Greška se od izlaznog sloja mreže propagira unazad, pri čemu se računaju gradijenti funkcije gubitka u odnosu na parametre sloja. Dobijeni gradijenti se koriste dalje za ažuriranje težina mreže [8].

3.5.9 Optimizacioni algoritam Adam

U procesu treniranja mreže potrebno je ažurirati vrednosti parametara, što se radi optimizacionim algoritmom. Jedan od optimizacionih algoritama je Adam (*Adaptive Moment Estimation*), koji se koristi pri obučavanju modela u okviru ovog rada.

Adam je gradijentni optimizacioni algoritam koji za svaki parametar mreže održava adaptivne procene prvog i drugog momenta gradijenta [11]. Ovaj optimizacioni algoritam je pogodan za optimizaciju mreža sa velikim brojem parametara.

Pojednostavljeno, Adam zadržava eksponencijalne pokretne proseke gradijenata:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

kao i kvadrate gradijenata

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

gde je g_t gradijent u tekućem koraku. Na osnovu ovih vrednosti se dalje određuje veličina izmene pojedinačnih parametara.

3.5.10 Augmentacija podataka

Performanse neuronskih mreža jako zavise od raznovrsnosti podataka koji se koriste za proces obučavanja, što je kod mreža koje treba da prepoznaju slike još izraženije. Jedno rešenje ovog problema je da se skup podataka za trening proširi novoprikupljenim podacima, što je u većini slučajeva slabo izvodljivo jer prikupljanje novih podataka zahteva dodatnih resursa i vremena. Jedno od pogodnijih rešenja ovog problema je postupak augmentacije podataka (*eng. data augmentation*) [8].

Augmentacija podataka predstavlja postupak transformacije već postojećih slika unutar trening skupa, kao što su rotacija, promena položaja, zumiranje, promena kontrasta i zamućenje. Cilj ovog postupka je da obogati trening skup slika sa slikama koje sadrže posmatrane objekte u većem broju varijacija, bez potrebe za prikupljanjem novih podataka za trening skup.

Koristiti augmentaciju podataka na skupu podataka koji se sastoji od slika saobraćajnih znakova je od izuzetne važnosti, jer se saobraćajni znakovi u realnim uslovima mogu naći na različitim pozicijama, udaljenostima, pod različitim uglovima i pri različitim osvetljenjima.

4. Implementacija sistema za prepoznavanje saobraćajnih znakova

4.1 Korišćene tehnologije

Sistem za prepoznavanje saobraćajnih znakova razvijen u okviru ovog rada implementiran je u programskom jeziku *Python*. Za delove koji obuhvataju obradu slike i računarski vid korišćena je biblioteka *OpenCV,* a za deo koji obuhvata mašinsko učenje, odnosno konvolutivnu neuronsku mrežu korišćena je biblioteka *TensorFlow/Keras*. Pored ovih glavnih biblioteka korišćena je i biblioteka *NumPy* za rad sa višedimenzionim i numeričkim podacima.

4.1.1 *Python*

Python je viši programski jezik opšte namene. Karakteristike po kojima je prepoznatljiv je relativno jednostavna i čitljiva sintaksa, dinamičko određivanje tipova podataka i mogućnost korišćenja različitih paradigmi programiranja. Osim standardne biblioteke koja je opširna, ovaj programski jezik poseduje veliki broj biblioteka koje služe za oblasti računarstva, obrade podataka, računarskog vida, mašinskog učenja i druge [12].

Jedna od najvećih prednosti ovog programskog jezika je povezanost sa programskim jezicima nižeg nivoa, kao što su C i C++, što omogućava korišćenje biblioteka za oblasti koje zahtevaju više računarskih resursa pomoću interfejsa *Python* programskog jezika, dok su njihove implementacije napisane u jezicima nižeg nivoa, što ih čini jako efikasnim [12].

Pored do sada navedenih stvari, još jedan razlog zašto je baš korišćen ovaj programski jezik je to što su dostupne biblioteke *OpenCV* i *TensorFlow* koje omogućavaju lako i efikasno korišćenje i obradu slika, kao i metode mašinskog učenja.

4.1.2 *OpenCV*

OpenCV (Open Source Computer Vision Library) je biblioteka namenjena računarskom vidu i obradi slika. Ova biblioteka sadrži veliki broj već implementiranih algoritama kako klasičnog tako i savremenog računarskog vida i dostupna je u većem broju programskih jezika od kojih je jedan *Python* [13].

OpenCV ima modularnu strukturu koju čine funkcionalnosti za učitavanje i čuvanje slika, geometrijske transformacije, filtriranje, konverziju između prostora boja, izdvajanje kontura i mnoge druge metode za obradu slika [13].

U okviru ovog rada ova biblioteka se koristi za učitavanje ulaznih slika, konverziju iz RGB u HSV prostor boja, formiranje i obradu binarnih maski, izdvajanje povezanih regiona i određivanje kontura na slici. Pored svega ovoga ona se koristi i u postupku analize oblika za određivanje konveksnog omotača, aproksimaciju kontura, računanje geometrijskih karakteristika i fitovanje elipse.

4.1.3 *TensorFlow i Keras*

TensorFlow je platforma otvorenog tipa namenjena za razvoj i korišćenje modela mašinskog učenja. U okviru ove biblioteke omogućen je rad sa višedimenzionalnim nizovima, automatsko računanje gradijenata, pravljenje i obučavanje neuronskih mreža kao i čuvanje i učitavanje već istreniranih modela [14].

Keras je *API(eng. Application Programming Interface)* u okviru *TensorFlow* biblioteke koji omogućava definisanje neuronskih mreža, njihovo obučavanje, evaluaciju i korišćenje [14].

U okviru ovog rada ova biblioteka je korišćena za implementaciju konvolutivne neuronske mreže za klasifikaciju prethodno detektovanih saobraćajnih znakova. Pomoću *Keras API*-a definisana je arhitektura mreže koja obuhvata konvolutivne slojeve, normalizacione slojeve, *MaxPooling* i *Dropout* slojeve, kao i potpuno povezani sloj za klasifikaciju na kraju mreže.

Pored ovoga biblioteka *TensorFlow* je korišćena i za učitavanje i pripremu skupa podataka, podelu podataka na trening i validacioni skup, augmentaciju podataka, obučavanje same mreže i praćenja procesa obučavanja. Nakon svega ovoga model se čuva u datoteci, koji se kasnije učitava u glavni program i vrši klasifikaciju znakova na novim slikama.

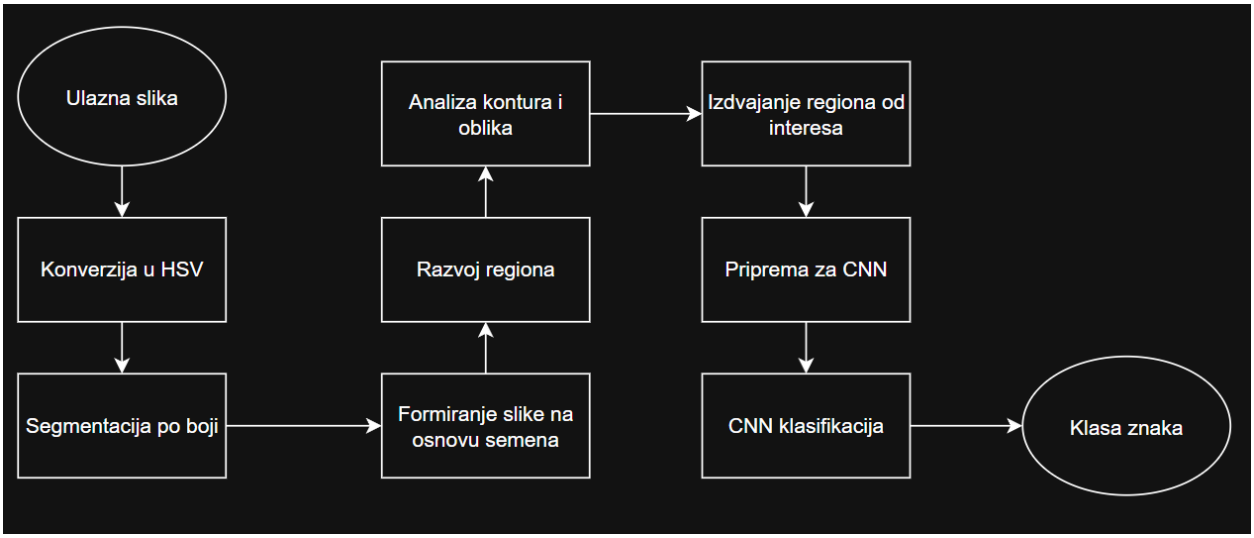
4.2 Arhitektura sistema

Arhitektura sistema koji je razvijen u okviru ovog rada čine više faza u okviru kojih su implementirane metode klasičnog računarskog vida i mašinskog učenja. Rad sistema zasniva se prvo na izdvajanju regiona od interesa na kojima su potencijalni saobraćajni znakovi korišćenjem metoda klasičnog računarskog vida, a potom klasifikacija potencijalnih znakova koji se nalaze na regionima od interesa pomoću konvolutivne neuronske mreže.

Rad čitavog sistema mogao bi se podeliti u narednih nekoliko faza:

1. Učitavanje ulazne slike
2. Segmentacija slike po boji
3. Formiranje semenih tačaka
4. Razvoj regiona
5. Izdvajanje i analiza kontura
6. Analiza oblika potencijalnih saobraćajnih znakova
7. Pirprema regiona od interesa za ulaz u neuronsku mrežu
8. Klasifikacija pomoću konvolutivne neuronske mreže
9. Prikaz rezultata klasifikacije

Rad sistema se takođe može prikazati blok dijagramom prikazanom na slici 4.1.



Slika 4.1 Blok dijagram rada sistema

Početna faza sistema je učitavanje same slike na kojoj se nalaze potencijalni saobraćajni znakovi. Ova slika predstavljena je u RGB format-u.

Nakon učitavanja ulazne slike, ona se konvertuje u HSV prostor boja. Na osnovu unapred određenih pragova proveravaju se sve tri HSV komponente svakog piksela i na taj način se formira binarna maska u okviru koje su svi pikseli koji pripadaju opsegu crvene boje predstavljeni vrednostima bele boje, dok su svi ostali pikseli predstavljeni nulama i čine pozadinu slike.

Binarna maska koja se dobija može sadržati veliki broj regiona koji nužno ne predstavljaju saobraćajni znak, a pripadaju odgovarajućoj boji znaka. Iz tog razloga se na osnovu ove maske formira slika na osnovu semena. Binarna maska deli se na blokove sa određenim brojem piksela tako da se za svaki blok određuje semena tačka. Nakon toga vrši se analiza povezanih komponenti binarne maske i formiraju se regioni koji sadrže najmanje jednu prethodno određenu semenu tačku.

Nakon ove faze dobija se maska sa regionima koji po svojoj boji mogu odgovarati saobraćajnim znakovima. Međutim samo na osnovu boji nije moguće razaznati da li dati regioni odgovaraju saobraćajnom znaku jer se u saobraćaju mogu naći i drugi objekti sličnih boja.

Iz ovih razloga u narednoj fazi vrši se analiza oblika. Na osnovu prethodno dobijene maske, izdvajaju se konture regiona, nakon čega se na osnovu njih za svaki region određuju njegove geometrijske karakteristike. Analiziraju se geometrijske karakteristike kao što su površina, obim, eliptičnost, oktaugaonalnost, kružnost, broj temena, odnos stranica, kompaktnost regiona i karakteristike fitovane elipse.

Kombinovanjem ovih geometrijskih karakteristika može se zaključiti koje regione je potrebno odbaciti jer svojim oblikom ne odgovaraju očekivanim saobraćajnim znakovima. Pošto ovaj sistem treba da prepozna znak “STOP” i znakove ograničenja brzine, sistem ostavlja sve regione kružnog, odnosno eliptičnog oblika kao i regione osmougaonog oblika.

Za svaki region koji je prošao fazu analize oblika dodatno se određuje i pravougaona oblast koja ga okružuje i iz originalne slike se izdvaja region od interesa (*eng. Region of Interest - ROI*). Pošto je konvolutivna neuronska mreža trenirana na slikama koje su u RGB formatu potrebno je uzeti region iz originalne slike, a ne sa binarne maske.

Regione od interesa je potrebno pripremiti za dalji ulaz u konvolutivnu neuronsku mrežu. Svaki region od interesa skalira se na veličinu koja odgovara ulaznom sloju mreže i vrši se potrebna konverzija rasporeda kanala po boji. Na ovaj način svaki od potencijalnih znakova dobija jedinstvenu reprezentaciju nezavisno od njegove originalne veličine na početnoj slici.

Nakon pripreme, region služi kao ulaz u već obučenu konvolutivnu neuronsku mrežu. Prethodne faze koje su uključivale metode klasičnog računarskog vida imale su za cilj da utvrde da li dati region može biti kandidat za saobraćajni znak, dok neuronska mreža za cilj ima određivanje konkretne klase znaka.

Mreža na svom izlazu za svaku klasu za koju je trenirana daje izlazne verovatnoće pripadnost regiona datoj klasi. Za rezultat konačne kalsifikacije uzima se ona klasa sa najvećom izlaznom verovatnoćom, uz proveru minimalnog nivoa pouzdanosti predikcije.

Poslednja faza predstavlja prikaz rezultata. Na originalnoj slici označava se položaj detektovanog saobraćajnog znaka pomoću pravougaonika i prikazuje se njegova predviđena klasa.

Detaljnija implementacija svake od navedenih faza biće data u narednim poglavljima.

4.3 Segmentacija po boji

Prvu fazu detekcije potencijalnih saobraćajnih znakova čini segmentacije slike po boji. Cilj ove faze je da sa originalne slike izdvoji sve regione koji imaju vrednosti boja koje odgovaraju unapred određenim pragovima i na taj način smanje površinu na kojima bi potencijalno mogli da se nađu saobraćajni znakovi. Sam postupak segmentacije u okviru ovog rada urađen je po ugledu na algoritam otporan na senke i osvetljenje (*eng. Shadow and Highlight Invariant Algorithm*) koji je u svom radu predstavio Fleyeh [5]. Osnovni koncept ovog algoritma je da sliku u HSV prostoru pretvori u binarnu masku tako da budu označeni pikseli željene boje, a odbačeni svi oni kod kojih boja nije dovoljno izražena ili su previše tamni, odnosno drugim rečima previše osvetljeni.

Segmentacija se radi na osnovu crvene boje jer znak „STOP“ i znakovi ograničenja brzine sadrže crvene površine koje ih čine izdvojive za algoritam segmentacije po boji.

Segmentacija po boji mogla bi se podeliti u narednih nekoliko faza:

1. Konverzija ulazne slike iz RGB prostora u HSV prostor
2. Formiranje binarne maske crvene boje
3. Formiranje slike na osnovu semena
4. Razvoj regiona.

4.3.1 Konverzija slike u HSV prostor

Ulazna slika se učitava koristeći biblioteku *OpenCV*. U okviru ove biblioteke slike su predstavljene u BGR formatu (slično poput RGB samo su kanali drugačije raspoređeni), pa se iz razloga navedenih u prethodnom poglavlju vrši direktna konverzija iz BGR u HSV prostora.

Za konverziju slike u HSV prostor boja korišćena je funkcija *cvtColor* biblioteke *OpenCV*.

Nakon same konverzije slika se razdvaja na tri matrice tako da svaka matrica odgovara svakoj od komponenti HSV prostora boja:

$$H(x, y), S(x, y), V(x, y)$$

Korišćenjem opsega [0, 255] odgovara načinu normalizacije koji je Fleyeh koristio u okviru svog rada gde su vrednosti sva tri kanala predstavljene u istom numeričkom opsegu [5]. Ovime se omogućava mogućnost direktnog definisanja pragova korišćenih u narednoj fazi.

Ovaj postupak se može opisati algoritmom 4.1.

Algoritam 4.1 – Konverzija ulazne slike u HSV prostor boja

Ulaz: BGR slika

Izlaz: H, S i V komponente

1. Konvertuj sliku iz BGR u HSV prostor funkcijom *cvtColor*
2. Izdvoj H komponentu
3. Izdvoj S komponentu
4. Izdvoj V komponentu
5. Vrati H, S i V.

4.3.2 Formiranje maske crvene boje

Nakon konverzije slike u HSV prostor vrši se izdvajanje piksela koji mogu pripadati crvenim površinama saobraćajnih znakova.

U implementaciji ovog sistema piksel se izdvaja ako ima crvenu boju u opsegu:

$$H < 15 \vee H > 235$$

Za pouzdano izdvajanje nije dovoljna samo *Hue* komponenta jer ne daje potpune informacije o crvenim regionima, pa su definisane granice i za komponente *Saturation* i *Value*:

$$S \geq 40$$

i

$$30 \leq V \leq 245$$

Odbacuju se pikseli sa manjom vrednosti zasićenosti jer kod njih boja nije dovoljno izražena da bi H komponenta predstavljala pouzdan kriterijum za segmentaciju.

Donja granica V komponente omogućava odbacivanje veoma tamnih regiona, dok gornja granica omogućava odbacivanje svetlih regiona kod kojih informacija o boji može biti nepouzdana.

Kao rezultat dobija se binarna maska u kojoj vrednost 255 predstavlja piksele koji zadovoljavaju kriterijum crvene boje, dok vrednosti 0 predstavljaju sve ostale piksele.

Ovaj postupak predstavljen je algoritmom 4.2.

Algoritam 4.2 – Formiranje maske crvene boje

Ulaz: H, S i V komponente slike

Izlaz: binarna maska M

Za svaki piksel (x, y):

Ako (H(x,y) < 15 ili H(x,y) > 235) i S(x,y) ≥ 40 i 30 ≤ V(x, y) ≤ 245

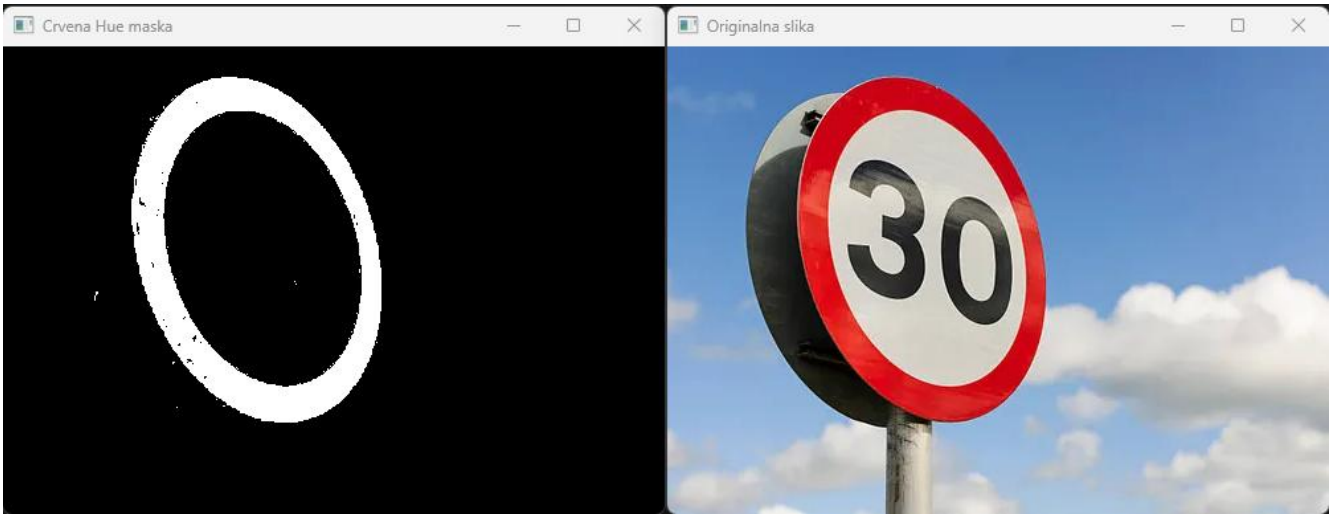
M(x, y) = 255

Inače

M(x, y) = 0

Vrati M.

Na slici 4.2 prikazan je primer znaka na originalnoj slici i binarna maska crvene boje.



Slika 4.2 Originalna slika i binarna maska crvene boje

4.3.3 Formiranje slike na osnovu semena

Binarna maska koja se dobija kao rezultat početne faze može da sadrži piksele koji su crvene boje ali ne moraju nužno pripadati saobraćajnom znaku. Iz tih razloga formira se posebna slika na osnovu semena koja ima svrhu da odredi semene tačke regiona koji sadrže dovoljnu koncentraciju piksela odgovarajuće boje.

Binarna maska se prvenstveno deli na kvadrante dimenzije 16 x 16 piksela, nakon čega se za svaku podsliku određuje tačan broj belih piksela, odnosno piksela čija je vrednost 255.

U implementaciji ovog sistema uzet je broj N_min = 30 kao minimalan broj belih piksela koji kvadrant mora imati da bi bio od interesa.

Nakon ovoga izdvaja se piksel koji se nalazi u samom geometrijskom centru kvadranta, i samim tim određuje beli piksel binarne maske koji se nalazi najbliže centru kvadranta. Ako je centar posmatranog kvadranta:

$$C = (x_c, y_c)$$

onda se za svaki piksel unutar kvadranta računa kvadrat euklidskog rastojanja:

$$d_i^2 = (x_i - x_c)^2 + (y_i - y_c)^2$$

Za seme uzima se onaj piksel za koji je ova vrednost minimalna.

Postupak formiranja slike na osnovu semena može se opisati algoritmom 4.3

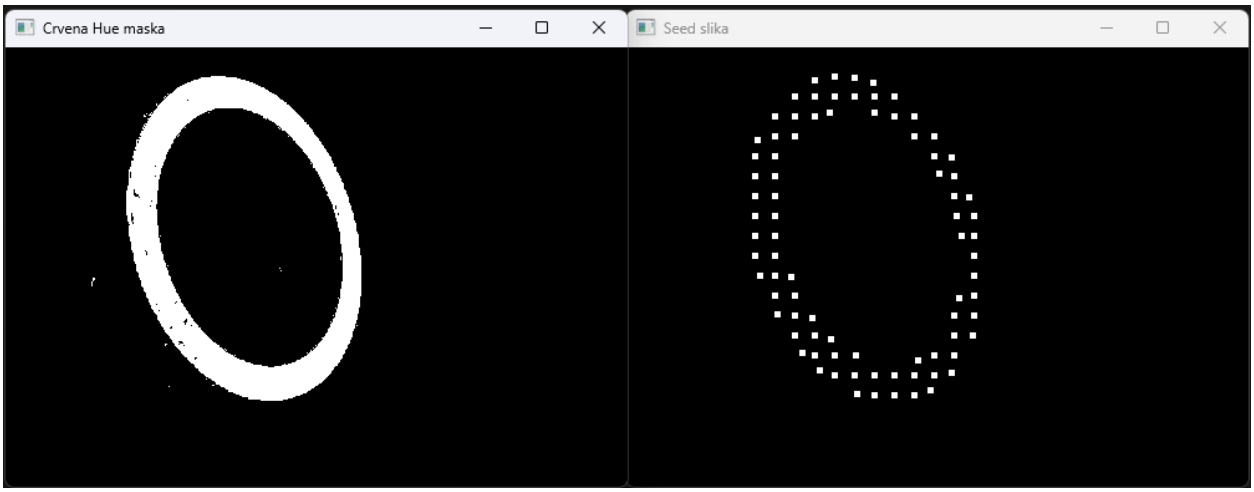
Algoritam 4.3 – Formiranje slike na osnovu semena

Ulaz: binarna maska M, veličina bloka = 16x16, minimalan broj belih piksela = 30

Izlaz: slika na osnovu semena

1. Napravi praznu crnu sliku S
2. Podeli M na blokove dimenzija 16 x 16
3. Za svaki blok:
    Izbroj broj belih piksela
    Ako broj belih piksela ≥ 30:
        Odredi centar bloka
        Pronađi sve bele piksele unutar bloka
        Izračunaj rastojanje od centra za svaki beli piksel
        Postavi odgovarajući piksel semena na 255
4. Vrati sliku S.

Na slici 4.3 sa leve strane dat je prikaz maske crvene boje a sa desne prikaz slike na osnovu semena tako da su pikseli skalirani zbog jasnijeg prikaza.



Slika 4.3 Slika na osnovu semena

4.3.4 Razvoj regiona

Poslednji korak segmentacije predstavlja određivanje regiona binarne maske koji su povezani sa prethodno određenim semenima. Ovaj postupak vrši se pomoću povezanih komponenti binarne slike.

Najpre se svi pikseli binarne slike koji su bele boje smatraju kao potencijalni članovi regiona. Potom se korišćenjem *OpenCV* funkcije određuju povezani regioni i dodeljuje im se oznake kako bi se na kraju odredile povezane komponente.

U implementaciji ovog algoritma koristi se osmosusedstvo, što znači da se za svaki piksel posmatra osam njegovih suseda opisano u potpoglavlju 3.3.2.

Dva bela piksela su povezana ukoliko postoji put između njih koji čine horizontalni, vertikalni ili dijagonalni susedni beli pikseli.

Nakon dobijanja svih povezanih komponenti ispituje se kojim tačno komponentama pripadaju semene tačke. Zadržavaju se isključivo regioni koji sadrže barem jednu semenu tačku, dok se svi ostali regioni ne uzimaju u obzir.

Ovaj postupak opisan je algoritmom 4.4.

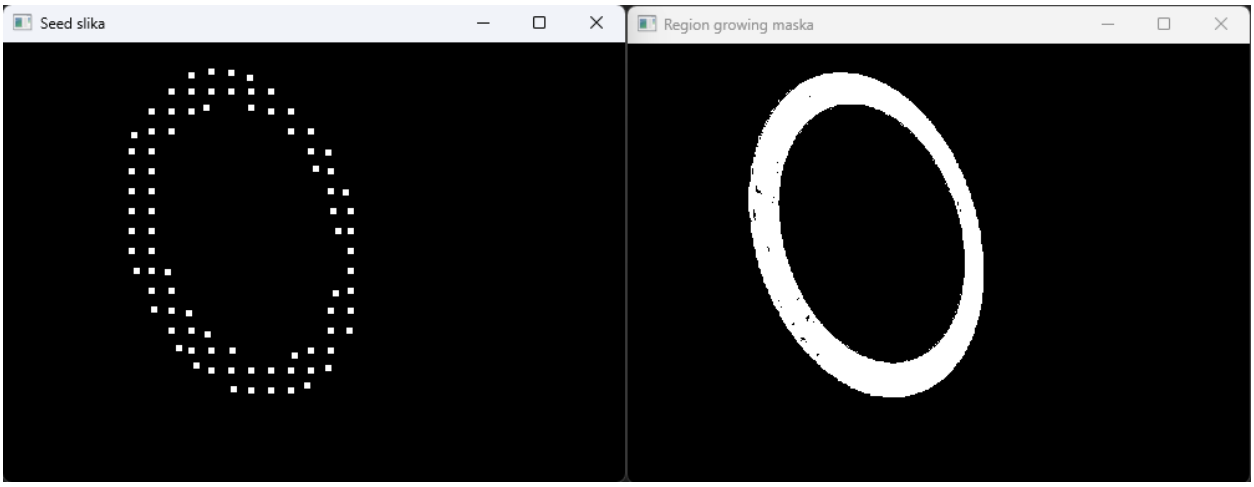
Algoritam 4.4 – Razvoj regiona

Ulaz: binarna maska M, slika na osnovu semena S

Izlaz: maska izdvojenih regiona R

1. Odredi sve 8-povezane komponente maske M
2. Dodeli oznaku svakoj komponenti
3. Izdvoj oznake svih komponenti koje sadrže bar jednu semenu tačku
4. Ukloni oznaku pozadine
5. Za svaku izdvojenu komponentu koja sadrži semenu tačku:
   Postavi sve njene piksele na 255 u izlaznoj maski R
6. Postavi vrednost svih ostalih piksela na 0
7. Vrati R

Na slici 4.4 prikazana je maska iz prethodne faze, kao i binarna maska nakon primene razvoja regiona.



Slika 4.4 Binarna maska pre i nakon razvoja regiona

Rezultat segmentacije po boji predstavlja binarna maska na kojoj su belim pikselima označeni regioni crvene boje sa originalne slike tako da svaki region ima dovoljnu koncentraciju ovakvih piksela. Ovi regioni nužno ne predstavljaju saobraćajne znakove, jer mogu to biti i drugi objekti crvene boje, pa se iz tih razloga ova maska prosleđuje kao ulaz za dalju analizu oblika.

4.4 Analiza oblika

S obzirom da nakon segmentacije po boji nije moguće prepoznati konkretne znakove, nakon segmentacije vrši se analiza oblika.

Ovaj postupak urađen je na sličan način kao što je to Fleyeh uradio u svom radu [5]. To je da se dobijeni za dobijene regione nađu geometrijske karakteristike i uporede sa očekivanim vrednostima za korektne oblike saobraćajnih znakova. Za ovo se koriste momentne invarijante i sličnost sa idealnim geometrijskim oblicima.

S obzirom da se ovaj sistem fokusira na znak „STOP“ i znakove ograničenja brzine, nije potrebno analizirati sve saobraćajne znakove pa je samim tim analiza ograničena na dve grupe potencijalnih kandidata:

- Osmougaone regione, koji mogu predstavljati znak „STOP“
- Kružne, odnosno eliptične regione, koji mogu predstavljati znakove ograničenja brzine

Pored eliptičnosti i oktagonalnosti, u obzir se uzimaju i dodatne geometrijske karakteristike, poput kružnosti, broj temena aproksimirane konture, solidnost, odnos stranica i karakteristike fitovane elipse. Zajedničkim uzimanjem u obzir više ovih karakteristika moguće je izbeći pogrešne procene i time preciznije odrediti odgovarajuće oblike znakova.

Implementacija analize oblika može se podeliti na tri faze:

1. Izdvajanje kontura i nalaženje konveksnog omotača
2. Izračunavanje geometrijskih karakteristika regiona
3. Klasifikacija regiona na kružni, osmougaoni ili neodgovarajući kandidat

4.4.1 Izdvajanje kontura i konveksnog omotača

Ulaz u ovu fazu predstavlja binarna maska dobijena segmentacijom po boji iz prethodnog poglavlja. U njoj belim pikselima su označeni regioni koji su prošli segmentaciju po boji i razvoj regiona.

Početni korak predstavlja određivanje spoljašnjih kontura ovih regiona. Za ovo koristi se funkcija *findContours* biblioteke *OpenCV*. Konture su predstavljene skupom tačaka koje čine granice izdvojenih regiona.

Za svaki izdvojeni region izračunava se njegova površina. Regioni koji imaju veoma malu površinu se pre računanja drugih geometrijskih karakteristika odbacuju, jer najčešće predstavljaju šum.

Nakon toga za konturu se formira konveksni omotač pomoću funkcije *convexHull* biblioteke *OpenCV*. Prilikom segmentacije po boji dobijene konture saobraćajnih znakova ne moraju biti potpuno pravilne, na nekim mogu postojati manja udubljenja i prekidi nastali zbog osvetljenja ili šuma, pa se iz tih razloga koristi konveksni omotač jer on omogućava da takve lokalne nepravilnosti mogu da se zanemare u nekoj meri tokom analize oblika.

Ovaj postupak se može predstaviti algoritmom 4.5.

Algoritam 4.5 – Izdvajanje kontura i priprema regiona

Ulaz: binarna maska sa segmentiranim regionima

Izlaz: skup kontura pogodnih za analizu oblika

1. Nađi spoljašnje konture binarne maske
2. Za svaku od nađenih kontura:
   Izračunaj površinu konture
   Ako je površina manja od minimalne:
      Odbaci konturu
      Nastavi sa narednom konturom

   Formiraj konveksni omotač

   Prosledi konturu i konveksni omotač postupku za izračunavanje geometrijskih karakteristika.

4.4.2 Izračunavanje geometrijskih karakteristika

U ovoj fazi se za svaki region koji je prošao prethodnu fazu izračunava skup geometrijskih karakteristika, čije su teorijske osnove date u poglavlju 3.4, dok će u nastavku biti navedene karakteristike koje se konkretno koriste u samoj implementaciji sistema.

Za početak se izračunavaju površina (A) i obim (P) datog regiona. Ovo su osnovne geometrijske karakteristike i koriste se za odbacivanje neodgovarajućih regiona, kao i za izračunavanje drugih geometrijskih karakteristika. Površina se koristi za eliminisanje veoma malih regiona, dok je obim potrebno izračunati za određivanje kružnosti.

Na osnovu momenata regiona vrši se proračun prvog afinog momenta invarijanti:

$$I_1 = \frac{\mu_{20}\mu_{02} - \mu_{11}^2}{\mu_{00}^4}$$

U implementaciji sistema se I_1 računa na osnovu konveksnog omotača regiona da bi se smanjio uticaj nepravilnosti originalne konture.

Za procenu sličnosti regiona elipsi koristi se referentna vrednost:

$$I_E = \frac{1}{16\pi^2}$$

Sličnost vrednosti I_1 i referentne vrednosti I_E predstavlja eliptičnost.

Definisana je minimalna vrednost eliptičnosti E_{min} = 0.92. Regioni čija eliptičnost ima manju vrednosti od ove minimalne se odbacuju kao kandidati za kružni znak.

Na sličan način se određuje oktagonalnost. Kao referentna vrednost uzima se:

$$I_E = \frac{1}{15.932\pi^2}$$

Kao i eliptičnost, oktagonalnost predstavlja odnos mera I_1 i I_E. Definisana je minimalna vrednost oktagonalnosti O_{min} = 0.94. Visoka vrednost oktagonalnosti koja zadovoljava ovaj uslov koristi se za izdvajanje znaka „STOP“.

Kružnost regiona se računa na osnovu njegovog obima i površine na sledeći način:

$$C = \frac{4\pi A}{P^2}$$

Kružni oblici imaju vrednost ove mere blisku jedinici. Ova karakteristika se koristi kao dodatni kriterijum pri određivanju kružnih i osmougaonih regiona.

Kao mera kompaktnosti koristi se solidnost i definisana je odnosom površina originalne konture i konveksnog omotača:

$$S_o = \frac{A}{A_{CH}}$$

gde je A_{CH} površina konveksnog omotača.

Definisana je vrednost minimalne solidnosti S_{0min} = 0.78. Regioni čija je solidnost manja od minimalne se odbacuju jer velika razlika između površine konture i površine konveksnog omotača može ukazivati na postojanje izražene nepravilnosti regiona.

Takođe se za svaki region računa minimalni rotirani pravougaonik koji ga okružuje. Na osnovu stranica pravougaonika (w_r i h_r) računa se odnos:

$$AR = \frac{w}{h}$$

Ukoliko ova karakteristika ima vrednost blizu jedan to znači da su dimenzije jednake u oba pravca, dok mala vrednost ukazuje na to da je objekat izdužen. Pa se samim tim ovaj kriterijum koristi za

odbacivanje veoma izduženih regiona koji svojom geometrijom ne mogu da se okarakterišu ni kao znakovi ograničenja brzine ni kao znak "STOP".

Sem momentnih mera, za analizu oblika vrši se i aproksimacija konture mnogouglom. Za ovo koristi se funkcija *approxPolyDP* iz *OpenCV* biblioteke koja impelemtira Daglas-Pekerov algoritam [15].

Sistem koristi dve aproksimacije različite preciznosti. Grublja aproksimacija omogućava izdvajanje dominantne geometrijske strukture objekta, dok finija zadržava veći broj detalja konture.

Za znakove koji mogu predstavljati znak ograničenja brzine se još vrši fitovanje elipse na izdvojenu konturu pomoću funkcije *fitEllipse* iz *OpenCV* biblioteke.

Pomoću male i velike elipse određuje se njihov odnos:

$$R_E = \frac{a_{min}}{a_{max}}$$

Što je vrednost R_E bliža jedinici to je fitovana elipsa sličnija krugu. Znakovi koji su kružnog oblika pod uglom se mogu pojaviti kao elipse, pa je ova geometrijska karakteristika jako korisna u tim situacijama.

Pored računanja odnosa osa, računa se i odnos površine regiona i površine fitovane elipse. Ovime se proverava koliko dobro odgovara površina posmatranog regiona elipsi koja se fituje na njegovu konturu.

Skup izračunatih geometrijskih karakteristika se može predstaviti na sledeći način:

$$F = \{A, P, I_1, E, O, C, S_0, AR_r, N_v, R_e, R_f\}$$

gde N_v predstavlja broj temena aproksimirane konture, a R_f odnos površine regiona i fitovane elipse.

Kombinovanjem ovih karakteristika može se doneti konačna odluka o obliku regiona.

4.4.3 Prepoznavanje kružnih i osmougaonih kandidata

Nakon izračunavanja geometrijskih karakteristika vrši se klasifikacija oblika regiona. U ovoj fazi ne određuje se konkretna klasa znaka, već mogućnost znaka da pripada nekoj klasi na osnovu svog oblika. Postoje tri moguća rezultata:

1. Region je kandidat za znak "STOP"
2. Region je kandidat za znak ograničenja brzine
3. Region se odbacuje

Najpre se vrši odbacivanje onih regiona čija je površina jako mala, regiona čija je solidnost ispod minimalne vrednosti, kao i regiona čiji odnos stranica ukazuje na to da su previše izduženi.

Prvo se vrši provera da li region predstavlja osmougao. Za znak "STOP" najznačajnije geometrijske karakteristike su oktagonalnost i broj temena aproskimirane konture. Zbog nepravilne segmentacije može doći do pojava nepravilnosti i nemogućnost savršenog poklapanja sa osmouglom, pa se iz tih razloga u obzir kružnost, solidnost i ostale geometrijske karakteristike.

Ukoliko regiona može predstavljati osmougaoni znak, nakon toga se proverava da li postoji mogućnost za znak predstavlja kružni znak ograničenja brzine, pa se u tom slučaju posmatraju eliptičnost, kružnost, odnos osa fitovane elipse, popunjenost elipse i broj temena aproksimirane konture.

Momentne vrednosti idealne elipse i idealnog osmougla su međusobno jako bliske pa je bitno poštovati ovaj redosled provere. Iz tih razloga sama eliptičnost ili oktagonalnost ne mogu odrediti konkretan oblik znaka, pa je potrebno u obzir uzeti i druge geometrijske karakteristike pri donošenju odluke o obliku znaka.

Ovaj postupak se može predstaviti algoritmom 4.6.

Algoritam 4.6 – Klasifikacija oblika izdvojenog regiona

Ulaz: kontura izdvojenog regiona

Izlaz: kandidat znaka "STOP", kandidat znaka ograničenja brzine ili odbačen region

1. Izračunaj površinu regiona
2. Ako je region previše mali:

        Odbaci region

3. Formiraj konveksni omotač
4. Izračunaj: afini momenti invarijanti, eliptičnost, oktaugaonalnost, kružnost, solidnost, odnos stranica, aproksimacije konture, broj temena, karakteristike fitovane elipse
5. Ako je solidnost manja od minimalne:
        Odbaci region
6. Ako je region previše izdužen:
        Odbaci region
7. Proveri kriterijume osmougaonog oblika:
        Ako oktagonalnost, broj temena i dodatne geometrijske karakteristike zadovoljavaju kriterijume:
            Označi region kao kandidat znaka "STOP"
8. U suprotnom proveri kriterijume kružnog, odnosno eliptičnog oblika:
        Ako eliptičnost, kružnost, karakteristike fitovane elipse i broj temena zadovoljavaju kriterijume:
            Označi region kao kandidat za znak ograničenja brzine

9. U suprotnom:
   Odbaci region
10. Vrati rezultat

Bitno je spomenuti da ovo nije konačna klasifikacija, već se na osnovu ovoga izdvajaju regioni od interesa koji se kasnije daju konvolutivnoj neuronskoj mreži za konačnu klasifikaciju, pa samim tim i nije toliko bitno ukoliko dođe do mešanja nekih od kružnih i osmougaonih kandidata, jer kasnije mreža može ispraviti ovo konačnom kalsifikacijom.

4.5 Izdvajanje regiona od interesa

Nakon segmentacije po boji i analize oblika dobijene regione je potrebno izdvojiti iz originalne slike i pripremiti ih za ulaz u konvolutivnu neuronsku mrežu.

Delovi slike koji se izdvoje nazivaju se regioni od interesa (*eng. Region of Interest - ROI*). U procesu segmentacije i analize oblika koristi se binarna maska, dok je ovde potrebno izdvojiti regione originalne slike jer je neuronska mreža istrenirana na slikama koje sadrže teksturu, boju i druge elemente. Ovo je isključivo bitno za znakove ograničenja brzine, jer se oni međusobno razlikuju po ciframa na znaku, i da bi mreža uspela da prepozna takve karakteristike potrebno joj je proslediti takav format slike.

Postupak izdvajanja mogao bi se podeliti na narednih nekoliko faza:

1. Određivanje graničnog pravougaonika detektovanog kandidata
2. Proširivanje granica regiona
3. Izdvajanje regiona iz originalne slike
4. Skaliranje regiona
5. Konverzija redosleda kanala
6. Formiranje odgovarajućeg ulaza za konvolutivnu neuronsku mrežu

4.5.1 Određivanje graničnog pravougaonika

Za svaki region koji je izdvojen prethodnim postupcima sada se određuje pravougaonik koji ga obuhvata na osnovu konveksnog omotača pomoću funkcije *boundingRect* biblioteke *OpenCV*.

Granični pravougaonik definisan je na sledeći način:

$$B = (x, y, w, h)$$

gde su:

- x i y koordinate gornjeg levog ugla pravougaonika
- w širina pravougaonika
- h visina pravougaonika

Korišćenje ovog pravougaonika dalje nije najbolja stvar jer postoji mogućnost da se znak previše tesno izdvoji. Nepotpunom segmentacijom se može postići to da spoljašnja ivica znaka ne bude obuhvaćena. Iz tih razloga je dalje potrebno dodatno proširivanje graničnog pravougaonika

4.5.2 Proširivanje regiona od interesa

Granični pravougaonik se u ovoj implementaciji proširuje za 10% njegove širine u horizontalnom pravcu i 10% njegove visine u vertikalnom pravcu, tako da minimalno proširenje u svakom pravcu bude dva piksela.

Veličine proširenja mogu se definisati kao:

$$p_x = max(2, round(0.10w))$$

$$Py = max(2, round(0.10h))$$

Pa su nove granice regiona date kao:

$$x_1 = max(0, x - p_x)$$

$$y_1 = max(0, y - p_y)$$

$$x_2 = min(W, x + w + p_x)$$

$$y_2 = min(H, y + h + p_y)$$

gde su W i H širina i visina originalne slike.

Funkcijama minimuma i maksimuma postiže se to da region izađe van granica originalne slike.

Ovaj postupak pomaže da ukoliko je došlo do nepotpune segmentacije znak bude obuhvaćen izdvojenom slikom.

4.5.3 Izdvajanje regiona iz originalne slike

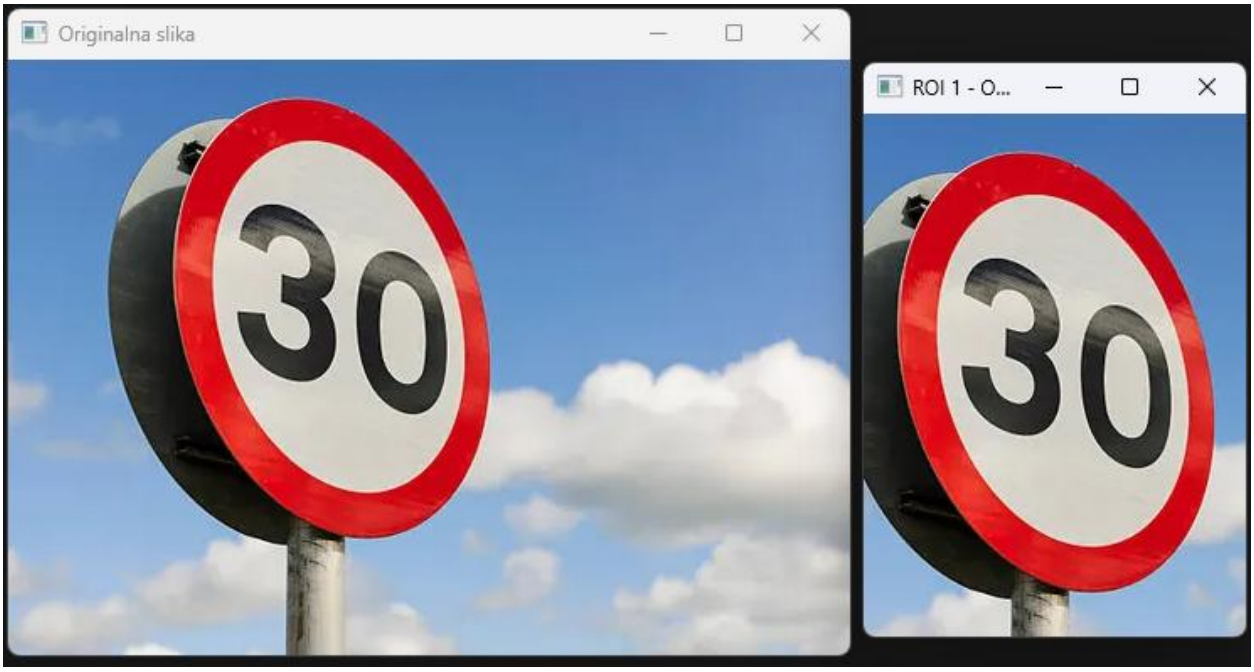
Nakon određivanja proširenih koordinata regiona od interesa vrši se njegovo izdvajanje iz originalne slike.

Ukoliko se originalna slika označi sa I, izdvojeni region od interesa se može predstaviti na sledeći način:

$$ROI = I[y_1, : x_1]$$

Ovim se zadržava originalna boja i sadržaj samog znaka.

Na slici 4.5 dat je prikaz primera izdvojenog regiona od interesa i originalne slike.



Slika 4.5 Izdvojeni region od interesa sa originalne slike

4.5.4 Skaliranje izdvojenog regiona od interesa

Regioni koji se izdvajaju mogu biti različitih dimenzija jer znakovi se mogu pojaviti u različitim veličinama zbog udaljenosti od kamere, rezolucije originalne slike, perspektive i drugih uslova slikanja.

Konvolutivna mreža koja se koristi u ovom radu očekuje ulaz fiksnih dimenzija pa je samim tim potrebno skalirati izdvojeni region od interesa na dimenzije:

$$64\ x\ 64$$

Piksela.

S obzirom da se koriste slike koje imaju tri kanala, svaki izdvojeni region ima dimenzije:

$$64\ x\ 64\ x\ 3$$

Ovaj postupak vrši se pomoću funkcije *resize* iz *OpenCV* biblioteke.

Na ovaj način vrši se standardizacija dimenzija slika koje se prosleđuju kao ulaz u neuronsku mrežu.

4.5.5 Konverzija redosleda kanala

Zbog implementacije *OpenCV* biblioteke kanali ulazne slike su raspoređeni kao BGR, dok neuronska mreža koja je trenirana očekuje da slika pri ulazu ima RGB raspored kanala pa je iz tih razloga potrebno obaviti konverziju redosleda kanala izdvojenog regiona od interesa pre ulaska u neuronsku mrežu.

Ovaj postupak vrši se pomoću funkcije *cvtColor* iz *OpenCV* biblioteke.

Jako je bitno ovo uraditi pre ulaska u mrežu jer ukoliko bi se mreži prosledile slike sa kanalima drugačijeg redosleda, ona ne bi korektno radila jer je trenirana isključivo na slikama odgovarajućeg formata.

4.5.6 Formiranje odgovarajućeg ulaza za konvolutivnu neuronsku mrežu

Nakon promene veličine i konverzije kanala, izdvojene regione je potrebno prilagoditi formatu ulaza koji očekuje istrenirani model korišćenjem *TensorFlow* biblioteke.

Trenutni region ima dimenzije 64 x 64 x 3 što nije odgovarajuće za ulaz u neuronsku mrežu jer ona očekuje ulaz organizovan u paketićima (*eng. batch*), pa je iz tih razloga potrebno svesti dimenzije izdvojenog regiona na 1 x 64 x 64 x 3. Gde prva dimenzija predstavlja broj slike koja se prosleđuje mreži u datom pozivu, i u ovom primeru ona ima broj jedan.

Takođe pre prosleđivanja mreži potrebno je sliku konvertovati u numerički tip *float32*.

Pored svega još jedan važan aspekat pripreme podataka za ulaz u mrežu predstavlja normalizacija vrednosti piksela. Ovaj postupak se ne vrši u procesu pripreme regiona od interesa. Vrednosti piksela se ne dele sa 255 pre ulaska u neuronsku mrežu, već se mreži prosleđuju u originalnom obliku u opsegu [0, 255].

Ovo se radi iz razloga jer sama neuronska mreža unutar svoje arhitekture uključuje sloj za skaliranje sa faktorom $\frac{1}{255}$.

Unutar same mreže vrši se transformacija $x_{norm} = \frac{x}{255}$ čime se vrednosti piksela iz opsega [0, 255] prebacuju u opseg [0,1].

Na ovaj način se primenjuje isti postupak normalizacije koja se primenjuje i tokom obučavanja i tokom klasifikacije novih regiona, i samim time se takođe izbegava i problem dvostruke normalizacije ulaznih podataka.

Čitav proces izdvajanja i pripreme regiona od interesa može se predstaviti algoritmom 4.7.

Algoritam 4.7 – Izdvajanje i priprema regiona od interesa

Ulaz: originalna slika i granični pravougaonik detektovanog kandidata

Izlaz: pripremljeni region od interesa za klasifikaciju pomoću CNN

1. Izdvoj koordinate i dimenzije graničnog pravougaonika
2. Izračunaj horizontalno proširenje:
   p_x = 10% širine regiona, uz minimalnu vrednost od 2 piksela
3. Izračunaj vertikalno proširenje:
   p_y = 10% visine regiona, uz minimalnu vrednost od 2 piksela
4. Proširi granice pravougaonika
5. Ograniči nove koordinate tako da ne izlaze van granica originalne slike
6. Izdvoj region od interesa iz originalne slike
7. Konvertuj kanale region od interesa iz BGR u RGB format
8. Skaliraj veličinu regiona od interesa na 64 x 64 piksela
9. Konvertuj slike u tip *float32*
10. Dodaj još jednu dimenziju za paketiće tako da ulazne dimenzije budu 1 x 64 x 64 x 3
11. Vrati pripremljeni region od interesa

Rezultat ove vaze predstavlja slika koja predstavlja region od interesa pogodna za prosleđivanje neuronskoj mreži kao ulaz.

Za svaki od prosleđenih regiona od interesa izdvojenih na ovaj način, mreža pridružuje verovatnoće pripadnosti klasama korišćenim u okviru sistema. Finalna odluka da li se znak prihvata kao prepoznat zavisi od praga sigurnosti predikcije. U implementaciji ovog sistema predikcija mora imati sigurnost veću od 98% da bi se prihvatila.

4.6 Priprema podataka za proces obučavanja neuronske mreže

Pre ikakvog obučavanja neuronske mreže, s obzirom da se koristi GTSRB skup podataka i da ova implementacija sistema ne prepoznaje sve saobraćajne znakove potrebno je izdvojiti podatke iz dostupnog skupa podataka i organizovati ih.

Za obučavanje modela korišćene su slike koje su podeljene u zasebne direktorijume, tako da svaki direktorijum obuhvata podskup slika date klase. Ovaj način organizacije kasnije omogućava lakše

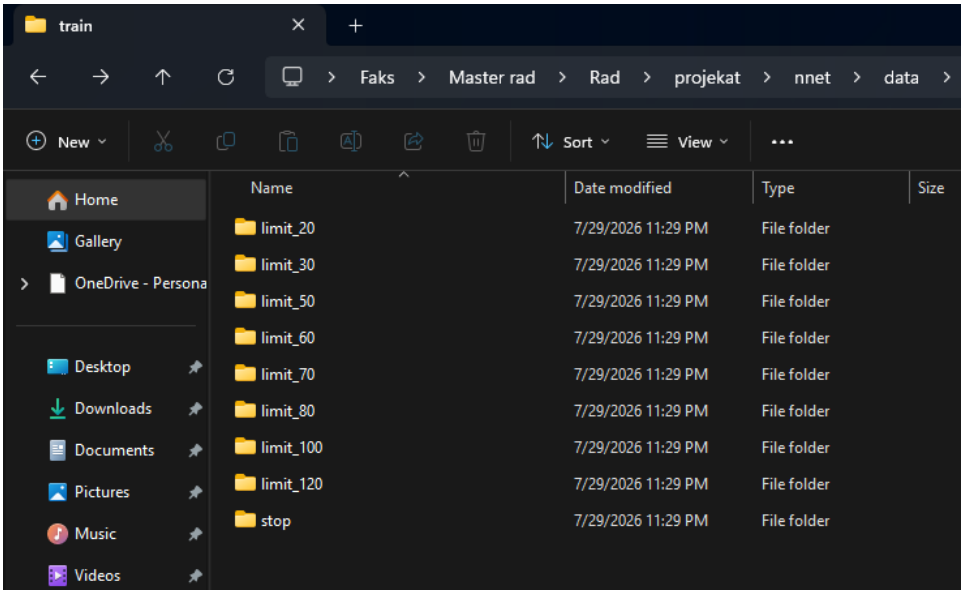
učitavanje podataka i automatsko dodeljivanje oznaka slikama na osnovu direktorijuma u kojem se nalaze.

Za obučavanje mreže koriste se skup slika znaka „STOP“ i skupovi slika ograničenja brzine vrednosti: 20 km/h, 30 km/h, 50km/h, 60 km/h, 70 km/h, 80 km/h, 100 km/h i 120 km/h.

4.6.1 Organizacija skupa podataka

Podaci su organizovani tako da se u direktorijumu data/train, nalaze direktorijumi sa slikama za svaku od gore navedenih klasa. Pre učitavanja podataka program prvo proverava da li glavni direktorijum postoji i da li su tu svi direktorijumi definisanih klasa, tako da ako ne postoje program prekida sa izvršavanjem i izbacuje odgovarajuću grešku.

Struktura podataka data je na slici 4.6.



Slika 4.6 Organizacija podataka

Svaki poddirektorijum sadrži skup slika odgovarajuće klase.

Funkcija *image_dataset_from_directory* biblioteke *TensorFlow* očekuje upravo ovakav način organizacije, pa se ona i koristi za učitavanje podataka jer ona automatski dodeljuje oznake slikama na osnovu naziva direktorijuma nakon učitavanja. U implementaciji koristi se *label_mode="int"* čime se svaka klasa predstavlja celobrojnom vrednošću.

4.6.2 Ujednačavanje dimenzija slika

Slike saobraćajnih znakova su različitih dimenzija pa da bi bile u odgovarajućem formatu za ulaz u neuronsku mrežu potrebno je svesti ih na iste dimenzije, odnosno 64 x 64 piksela.

S obzirom da se slike učitavaju u RGB formatu, dimenzije ulazne slike su 64 x 64 x 3.

Ovaj postupak je jako bitan jer svi podaci unutar paketića koji se prosleđuje neuronskoj mreži moraju biti iste dimenzionalnosti, a i ulazni sloj neuronske mreže očekuje unapred definisane slike unapred definisanih dimenzija.

4.6.3 Podela podataka na trening i validacioni skup

Čitav skup podataka deli se na dva dela: 70% podataka za obučavanje i 30% podataka za validaciju. U implementaciji je postavljen parametar *TEST_SPLIT* na vrednost 0.30.

Za obe podgrupe podataka slučajno seme *RANDOM_SEED* ima vrednost 123 kako bi podela podataka bila ponovljiva. Ovim jedna slika ne može pripadati i trening skupu i validacionom skupu jer *TensorFlow* biblioteka koristi *validation_split* i isto seme za formiranje obe podgrupe podataka. Dodatno se podaci za trening dodatno mešaju prilikom učitavanja.

4.6.4 Grupisanje podataka u paketiće

Slike za trening se mreži ne daju kao ulaz pojedinačno već se prosleđuju u manjim grupama koje se nazivaju paketići. Veličina ovih paketića podešena je parametrom *BATCH_SIZE* koji je u implementaciji sistema postavljen na vrednost 32. Ovo znači da u jednom prolazu kroz mrežu se obrađuju 32 slike, nakon čega se vrši ažuriranje parametara modela na osnovu njihovih grešaka. Korišćenjem paketića omogućava se efikasnije korišćenje memorije i stabilnije računanje gradijenata prilikom procesa obučavanja mreže.

4.6.5 Optimizacija učitavanja podataka

Da bi se smanjilo vreme čekanja između pojedinačnih prolaza tokom obučavanja, nad učitanim podacima vrše se operacije keširanja, mešanja i prethodnog učitavanja pomoću biblioteke *TensorFlow*.

Trening skup se prvo kešira, pa se potom meša korišćenjem parametra veličine bafera od 1000, a nakon toga se koristi *prefetch* sa podešenim parametrom *AUTOTUNE*. Validacioni skup se takođe kešira i priprema korišćenjem funkcije *prefetch*.

Ove operacije ne menjaju sam sadržaj podataka, već poboljšavaju efikasnost učitavanja i omogućavaju da se priprema narednog paketića podataka vrši paralelno sa obradom tekućeg paketića.

4.6.6 Augmentacija podataka

Pored osnovne pripreme podataka implementira se i augmentacija podataka (*eng. data augmentation*). Ovo se radi da bi se povećala raznovrsnost trening skupa vršenjem malih transformacija nad postojećim slikama. Augmentacija podataka se u ovom sistemu implementira korišćenjem narednih transformacija:

- Nasumična rotacija
- Nasumično skaliranje
- Nasumična translacija
- Nasumična promena kontrasta

Za vršenje ovih transformacija podešeni su naredni parametri:

- *RandomRotation* = 0.08
- *RandomZoom* = 0.10
- *RandomTranslation* = 0.08
- *RandomContrast* = 0.15

Ovim transformacijama mogu se simulirati manje promene koje se mogu pojaviti u realnim uslovima prilikom slikanja znakova, kao što su promena ugla posmatranja, promena položaja znaka na slici, različita udaljenost ili promenjeno osvetljenje.

Augmentacija se vrši isključivo tokom obučavanja modela, dok se prilikom validacije i kasnije klasifikacije ne vrše ovakve transformacije. Augmentacija je implementirana pomoću *Keras* platforme i nalazi se neposredno nakon ulaznog sloja.

4.6.7 Normalizacija vrednosti piksela

Vrednost piksela na originalnim slikama nalazi se u opsegu [0, 255]. Pre prosleđivanja podataka mreži vrši se normalizacija tako da se ove vrednosti svode na interval [0, 1]. Ovaj postupak vrši se pomoću *Keras* sloja *Rescaling* koristeći faktor $\frac{1}{255}$. Za pojedinačni piksel transformacija se može zapisati na sledeći način:

$$x_{norm} = \frac{x}{255}$$

Ovaj postupak se ne implementira kao zasebni deo, već je uključen kao deo same arhitekture neuronske mreže. Ovim se postiže da se ista normalizacija automatski primenjuje i tokom obučavanja modela i tokom kasnije klasifikacije.

4.6.8 Algoritam pripreme podataka

Čitav postupak pripreme podataka može se predstaviti algoritmom 4.8.

Algoritam 4.8 Priprema podataka za obučavanje CNN modela

Ulaz: direktorijum sa slikama organizovanih po klasama

Izlaz: trening i validacioni skup

1. Proveri da li postoji direktorijum sa podacima
2. Proveri da li postoje direktorijumi svih 9 klasa
3. Učitaj slike iz odgovarajućih direktorijuma
4. Svakoj slici dodeli odgovarajuću celobrojnu oznaku klase
5. Skaliraj sve slike na veličinu od 64 x 64 piksela
6. Podeli čitav skup podataka:
   70% trening,
   30% validacija
7. Podeli podatke u paketiće od 32 slike
8. Za trening podatke primeni: mešanje, keširanje i prethodno učitavanje
9. Za validacione podatke primeni: keširanje i prethodno učitavanje
10. Tokom treninga primenjuj: nasumičnu rotaciju, zumiranje, translaciju, promenu kontrasta
11. Izvrši normalizaciju piksela iz opsega [0, 255] u opseg [0, 1] unutar modela
12. Prosledi pripremljene podatke mreži za proces obučavanja

4.7 Konvolutivna neuronska mreža

Za finalnu klasifikaciju prethodno detektovanih kandidata saobraćajnih znakova razvijena je konvolutivna neuronska mreža koristeći biblioteke *TensorFlow/Keras*. Zadatak ove mreže je da detektovani region svrsta u jednu od devet klasa: osam za znakove ograničenja brzine i jednu za znak “STOP”.

Arhitektura mreže je realizovana sekvencijalno, tako da se slojevi izvršavaju istim redosledom kojim su navedeni u sklopu modela. Mreža kao ulaz očekuje RGB sliku dimenzija 64 x 64 x 3. Nakon ulaznog sloja vrši augmentacija i normalizacija podataka, a potom slede tri konvolutivna bloka sa gradacionim povećanjem broja filtera. Na kraju dolazi potpuno povezani sloj koji služi za klasifikaciju izdvojenih karakteristika u jednu od devet mogućih klasa.

4.7.1 Konvolutivni deo mreže

Konvolutivni deo mreže sačinjen je od tri konvolutivna bloka. Svaki od konvolutivnih blokova imaju dva konvolutivna sloja, nakon čega se vrši smanjenje prostornih dimenzija koristeći *MaxPooling* sloj. Takođe, koriste se i normalizacioni i Dropout slojevi koji služe za stabilizaciju procesa obučavanja mreže i smanjenje mogućnosti preprilagođavanja modela.

Prvi konvolutivni blok čine dva konvolutivna sloja sa po 32 filtera dimenzija 3 x 3. Oba sloja koriste ReLU aktivacionu funkciju isti proširenje, čime se zadržavaju prostorne dimenzije mape karakteristika nakon izlaska iz sloja. Između dva konvolutivna sloja vrši se normalizacija paketića, a nakon drugog sloja vrši se *MaxPooling* dimenzija 2 x 2 i *Dropout* sa verovatnoćom isključivanja neurona od 20%.

Drugi konvolutivni blok ima istu strukturu, samo što koristi 64 filtera u konvolutivnim slojevima. Koriste se filteri dimenzije 3 x 3, ReLU aktivaciona funkcija, normalizacija paketića i *MaxPooling*. Na kraju ovog bloka nalazi se *Dropout* sloj sa verovatnoćom isključivanja neurona od 25%.

Treći konvolutivni blok koristi dva konvolutivna sloja sa po 128 filtera dimenzija 3 x 3. Isto kao i u prethodnim slojevima koriste se ReLU aktivaciona funkcija, normalizacija paketića i *MaxPooling* na isti način. Na kraju bloka nalazi se *Dropout* sloj sa verovatnoćom isključivanja neurona od 30%.

Gradacionim povećavanjem broja filtera sa 32 na 64, a zatim i na 128, omogućava da se u dubljim slojevima mreže formiraju složenije mape karakteristika.

4.7.2 Klasifikacioni deo mreže

Na kraju tri konvolutivna bloka nalazi se *GlobalAveragePooling2D* sloj. Njime se računaju srednje vrednosti svake mape karakteristika i time smanjuje broj parametara u završnom delu mreže.

Dobijene karakteristike prosleđuju se potpuno povezanom sloju koji čini 128 neurona sa ReLU aktivacionom funkcijom.

Nakon ovog sloja takođe se nalazi *Dropout* sloj sa verovatnoćom isključivanja neurona od 40%.

Poslednji sloj ovog dela čine devet neurona, po jedan za svaku klasu, koji koriste *softmax* aktivacionu funkciju.

Izlaz koji softmax funkcija daje iz neuronske mreže može se predstaviti pomoću vektora:

$$P = [p_1, p_2, \ldots, p_3]$$

pri čemu svaka vrednost predstavlja procenjenu verovatnoću pripadnosti odgovarajućoj klasi, tako da važi:

$$\sum_{i=1}^{9} p_i = 1$$

Klasa koja ima najveću verovatnoću uzima se kao finalna predikcija mreže.

4.7.3 Arhitektura čitave mreže

Na slici 4.7 data je *TensorFlow* reprezentacija arhitekture mreže.

Model: "traffic_sign_cnn"

Layer (type)	Output Shape	Param #
data_augmentation (Sequential)	(None, 64, 64, 3)	0
rescaling (Rescaling)	(None, 64, 64, 3)	0
conv2d (Conv2D)	(None, 64, 64, 32)	896
batch_normalization (BatchNormalization)	(None, 64, 64, 32)	128
conv2d_1 (Conv2D)	(None, 64, 64, 32)	9,248
max_pooling2d (MaxPooling2D)	(None, 32, 32, 32)	0
dropout (Dropout)	(None, 32, 32, 32)	0
conv2d_2 (Conv2D)	(None, 32, 32, 64)	18,496
batch_normalization_1 (BatchNormalization)	(None, 32, 32, 64)	256
conv2d_3 (Conv2D)	(None, 32, 32, 64)	36,928
max_pooling2d_1 (MaxPooling2D)	(None, 16, 16, 64)	0
dropout_1 (Dropout)	(None, 16, 16, 64)	0
conv2d_4 (Conv2D)	(None, 16, 16, 128)	73,856
batch_normalization_2 (BatchNormalization)	(None, 16, 16, 128)	512
conv2d_5 (Conv2D)	(None, 16, 16, 128)	147,584
max_pooling2d_2 (MaxPooling2D)	(None, 8, 8, 128)	0
dropout_2 (Dropout)	(None, 8, 8, 128)	0
global_average_pooling2d (GlobalAveragePooling2D)	(None, 128)	0
dense (Dense)	(None, 128)	16,512
dropout_3 (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 9)	1,161

Total params: 305,577 (1.17 MB)
Trainable params: 305,129 (1.16 MB)
Non-trainable params: 448 (1.75 KB)

Slika 4.7 TensorFlow reprezentacija arhitekture konvolutivne neuronske mreže

4.7.4 Kompilacija modela

Nakon definisanja same arhitekture mreže potrebno je izvršiti kompilaciju mreže, odnosno definisati način optimizacije i definisati funkciju gubitka koja se koristi tokom procesa obučavanja mreže. Za proces optimizacije koristi se Adam optimizacioni algoritam sa stopom učenja $\eta = 0.001$. A za funkciju gubitka koristi se razređena kategorička unakrsna entropija.

Za praćenje performansi procesa učenja kao metrika koristi se tačnost klasifikacije (eng accuracy).

4.7.5 Parametri procesa obučavanja

Za samo obučavanje mreže koristi se trening skup podataka koji je opisan u prethodnom poglavlju, dok se validacioni skup koristi za praćenje mogućnosti generalizacije mreže tokom procesa obučavanja.

Maksimalni broj epoha postavljen je na $E_{max} = 50$, dok je veličina paketića podataka postavljena na $B = 32$.

Epoha predstavlja prolaz celog skupa podataka za trening kroz mrežu, međutim ne mora biti nužno izvršiti svih 50 epoha jer je u okviru mreže implementiran mehanizam ranog zaustavljanja.

4.7.6 Kontrola procesa obučavanja

Za kontrolu procesa obučavanja korišćene su sledeće tri tehnike implementirane *Keras* platforme:

- Rano zaustavljanje
- Kontrolna tačka modela
- Smanjenje koeficijenta učenja pri dostizanju platoa

Rano zaustavljanje prati vrednost funkcije gubitka na validacionom skupu, tako da ukoliko se ona ne poboljšava tokom sedam uzastopnih epoha, proces obučavanja se prekida. Ovo sprečava pojavu nepotrebnog daljeg treniranja modela kada ne dolazi do poboljšanja na validacionom skupu. Na kraju se vraćaju težine iz modela u kojoj je vrednost metrika na validacionom skupu bio najbolji.

Mehanizam kontrolne tačke modela, prati tačnost modela na validacionom skupu, tako da se model čuva isključivo ako se ostvari vrednost ovog parametra koja je bolja u odnosu na prethodne epohe. Ovim mehanizmom se na kraju čuva model koji je ostvario najbolje rezultate tokom obučavanja na validacionom skupu.

Mehanizam smanjenja koeficijenta učenja pri dostizanju platoa prati vrednost funkcije gubitka na validacionom skupu, tako da ukoliko se ne ostvaruje poboljšanje modela u toku nekoliko uzastopnih epoha vrši se smanjenje stope učenja.

Ukoliko se vrednost gubitka ne poboljša nakon tri uzastopne epohe stopa učenja množi se faktorom 0.5. Najmanja dozvoljena vrednost stope učenja iznosi 10^{-5}.

Ovim postupkom postiže se to da korak optimizacije bude veći u početnim fazama obučavanja modela, a da se u kasnijim fazama, kada se model približava minimumu funkcije gubitka, stopa učenja automatski smanjuje.

4.7.7 Obučavanje i čuvanje modela

Nakon definisanja arhitekture mreže, kompilacije i pripreme primene mehanizama za kontrolu procesa obučavanja započinje proces obučavanja mreže.

Mreži se prosleđuju trening i validacioni skupovi podataka i tokom svake epohe beleže se vrednosti tačnosti i funkcije gubitka nad oba skupa.

Nakon završetka procesa obučavanja, model se evaluira na validacionom skupu, pri čemu se određuju vrednosti gubitka i tačnosti.

Potom finalni model se čuva u datoteci *traffic_sign_cnn.keras* putem koje se mreža kasnije učitava u glavnom program i koristi za prepoznavanje saobraćajnih znakova.

Takođe tokom treninga čuvaju se i podaci o vrednostima tačnosti i gubitka za trening i validacioni skup podataka. Na osnovu ovih podataka formiraju se grafici promene tačnosti i gubitka tokom epoha, što kasnije služi za analizu rezultata neuronske mreže.

4.7.8 Algoritam formiranja i obučavanja konvolutivne neuronske mreže

Proces formiranja arhitekture i obučavanja konvolutivne neuronske mreže dat je algoritmom 4.9

Algoritam 4.9 - Formiranje i obučavanje konvolutivne neuronske mreže

Ulaz: trening skup i validacioni skup

Izlaz: obučena konvolutivna neuronska mreža

1. Formiraj ulazni sloj dimenzija 64 x 64 x 3
2. Dodaj slojeve za augmentaciju
3. Dodaj slojeve za skaliranje

4. Formiraj prvi konvolutivni blok:
   Konvolutivni sloj sa 32 filtera,
   Normalizacioni sloj,
   Konvolutivni sloj sa 32 filtera,
   MaxPooling sloj,
   Dropout sloj 20%
5. Formiraj drugi konvolutivni blok:
   Konvolutivni sloj sa 64 filtera,
   Normalizacioni sloj,
   Konvolutivni sloj 64 filtera,
   MaxPooling sloj,
   Dropout sloj 25%
6. Formiraj treći konvolutivni blok:
   Konvolutivni sloj sa 128 piksela,
   Normalizacioni sloj,
   Konvolutivni sloj sa 128 piksela,
   MaxPooling sloj,
   Dropout sloj 30%
7. Primeni globalno sažimanje po srednjoj vrednosti
8. Dodaj potpuno povezan sloj sa 128 neurona
9. Dodaj *Dropout* sloj 40%
10. Dodaj izlazni potpuno povezan sloj sa 9 neurona i softmax aktivacionom funkcijom
11. Izvrši kompilaciju modela:
    Adam,
    $\eta = 0.001$,
    Razređena kategorička unakrsna entropija,
    Tačnost
12. Definiši mehanizme kontrole procesa obučavanja
13. Obuči model sa maksimalnim brojem epoha 50, koristeći trening i validacioni skup
14. Evaluiraj obučeni model
15. Sačuvaj model u datoteku *traffic_sign_cnn.keras*
16. Sačuvaj rezultate treniranja modela potrebne za kasniju analizu

Nakon ovog procesa dobija se obučen model za prepoznavanje znakova koji se može koristiti nezavisno od samog procesa obučavanja. Ovaj model se kasnije u glavnom programu učitava i koristi za klasifikaciju izdvojenih regiona od interesa dobijenim segmentacijom po boji i analizom oblika.

4.8 Klasifikacija detektovanih znakova

Nakon završetka procesa segmentacije po boji, analize oblika i izdvajanja regiona od interesa ostalo je da se izvrši sama njihova finalna klasifikacija. Ovi regioni od interesa se prosleđuju obučenoj neuronskoj mreži koja daje rezultate konačne klasifikacije i nakon toga se vrši njihov prikaz.

4.8.1 Učitavanje obučenog modela

Pre finalne klasifikacije, prvo je potrebno učitati već obučen model konvolutivne neuronske mreže koji se nalazi u datoteci *traffic_sign_cnn.keras*. Ovo se postiže koristeći funkciju *load_model* biblioteke *Tensorflow/Keras*. Pre učitavanja proverava se da li odgovarajuća datoteka sa modelom uopšte postoji, tako da ako ne postoji program prestaje sa izvršavanjem i izbacuje grešku.

4.8.2 Prosleđivanje regiona od interesa neuronskoj mreži

Za svaki potencijalno detektovani saobraćajni znak sa originalne slike izdvaja se region od interesa, na način opisan u poglavlju 4.5.

Nakon skaliranja slike na veličinu 64 x 64 piksela, konverzije kanala i dodavanje dodatne dimenzije za paketiće podataka pripremljeni region se prosleđuje neuronskoj mreži.

Predikcija modela vrši se pomoću funkcije *model.predict* koja kao povratnu vrednost vraća niz od devet vrednosti koje predstavljaju vrednosti verovatnoće pripadnosti odgovarajućoj klasi.

4.8.3 Određivanje dodeljene klase

Proces određivanja dodeljene klase vrši se odabirom klase čija je verovatnoća pripadnosti najveća.

Ako se izlazi mreže označe sa p_i, indeks dodeljene klase se može odrediti na sledeći način:

$$\hat{\imath} = argmax_i p_i$$

Pa se dalje na osnovu ovog indeksa dobija konkretan naziv klase predviđenog saobraćajnog znaka.

Sigurnost predikcije predstavlja konkretnu maksimalnu vrednost izlaznog vektora i može se predstaviti:

$$C_{CNN} = max_i p_i$$

4.8.4 Prag sigurnosti klasifikacije

Iako se za finalnu klasu uzima najveća vrednost izlaznog vektora, to ne mora da znači da je predikcija dovoljno pouzdana da bi potencijalni znak pripadao određenoj klasi. Za primere znakova koje neuronska mreža nije videla ili nema dovoljno podataka može se desiti da najveća vrednost *softmax* funkcije može biti relativno mala.

Iz ovih razloga u ovoj implementaciji rada uveden je dodatni prag sigurnosti klasifikacije.

Njegova vrednost je $C_{min} = 0.98$. Odnosno znak se smatra klasifikovanim ukoliko verovatnoća koju mreža vrati ispunjava naredni uslov:

$$C_{CNN} \geq 0.98$$

Ukoliko ovaj uslov nije zadovoljen kandidat se uopšte ne uzima u obzir.

Nakon što se kroz mrežu provuku svi potencijalni kandidati za znakove, dobija se lista detekcija koja sadrži klase i pouzdanost svih kandidata. Ova lista se dalje filtrira koristeći gore navedeni uslov kako bi se dobila lista konačno klasifikovanih saobraćajnih znakova.

Vrednost ovog praga je za ovu konkretnu implementaciju sistema izabrana tako visoko da bi se izbegla pogrešna klasifikacija saobraćajnih znakova koji imaju slične koloristične i geometrijske karakteristike kao znakovi ograničenja brzine ili znak „STOP“ a ne pripadaju ovim klasama. Ova vrednost može uticati na broj dobijenih potencijalno korektno prepoznatih saobraćajnih znakova.

4.8.5 Prikaz konačnog rezultata

S obzirom da je sistem implementiran u okviru ovog rada pokaznog tipa, kao poslednji korak potrebno je prikazati dobijene detekcije na originalnoj slici.

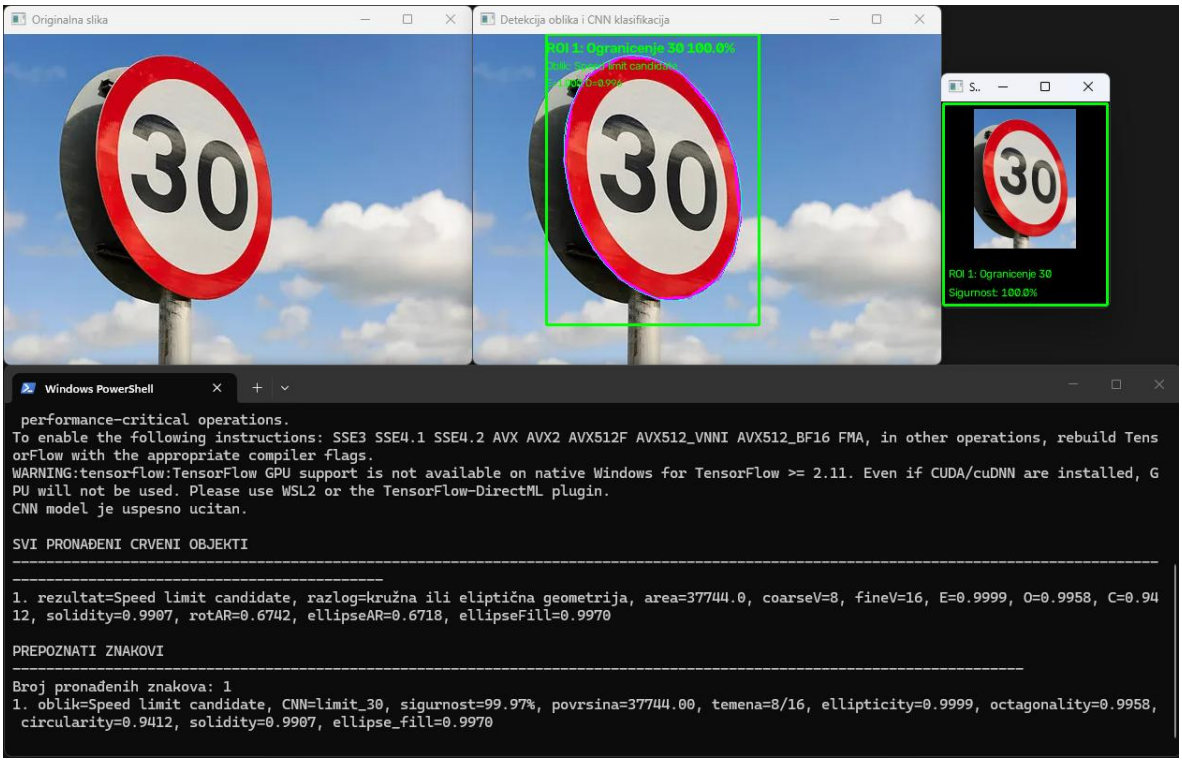
Za svaki prihvaćeni saobraćajni znak prikazuje se:

- Granični pravougaonik
- Naziv predviđene klase
- Sigurnost klasifikacije neuronske mreže
- Rezlutat analize oblika u terminalu

Pored ovog prikaza na originalnoj slici, sistem takođe generiše i prozor koji sadrži sve predikcije zajedno prikazane na gornje opisan način.

Pošto se na kraju vrši filtriranje detekcija na osnovu praga sigurnosti klasifikacije, na konačnom prikazu rezultata ostaju samo one detekcije koje zadovoljavaju ovaj kriterijum sigurnosti

Na slici 4.8 prikazan je prikaz konačnog rezultata klasifikacije saobraćajnog znaka.



Slika 4.8 Prikaz konačnog rezultata klasifikacije saobraćajnog znaka

Na slici 4.9 prikazan je prikaza konačnog rezultata klasifikacije za sliku koja sadrži više od jednog saobraćajnog znaka. Znak ograničenja brzine za 40 km/h nije prepoznat jer se u podacima za obučavanje mreže ne nalaze slike tog znaka tako da sistem i ne može da ga prepozna.



Slika 4.9 Prikaz konačnog rezultata klasifikacije za više saobraćajnih znakova

4.8.6 Čitav postupak klasifikacije

Postupak klasifikacije detektovanih kandidata predstavljen je algoritmom 4.10.

Algoritam 4.10 – Klasifikacija detektovanih saobraćajnih znakova

Ulaz: originalna slika, skup kandidata dobijenih analizom oblika, obučen model CNN

Izlaz: Konačna lista prepoznatih znakova

1. Učitaj obučen CNN model
2. Za svaki detektovani kandidat:
   Izdvoj region od interesa iz originalne slike
   Proširi region od interesa za 10%
   Konvertuj kanale iz BGR u RGB
   Skaliraj na veličinu 64x64
   Konvertuj podatke u tip *float32*
   Dodaj dimenziju za paketiće podataka
   Prosledi region od interesa CNN modelu
   Prihvati vektor verovatnoća za svaku klasu
   Odredi klasu sa najvećom izlaznom verovatnoćom
   Odredi sigurnost predikcije
3. Ako je sigurnost ≥ 0.98:
   Prihvati klasifikaciju
   Inače
   Odbaci kandidata
4. Za svaki prihvaćeni znak:
   Prikaži granični pravougaonik
   Prikaži naziv klase
   Prikaži procenat sigurnosti
   Ispiši rezultate analize oblika u terminal
5. Vrati konačan skup prepoznatih znakova

Ovim korakom završen je čitav postupak prepoznavanja saobraćajnih znakova sistema implementiranom u okviru ovog rada. Ulazna slika prvo prolazi kroz proces segmentacije po boji, analize oblika, izdvajanje regiona od interesa i konačnu klasifikaciju pomoću konvolutivne neuronske mreže.

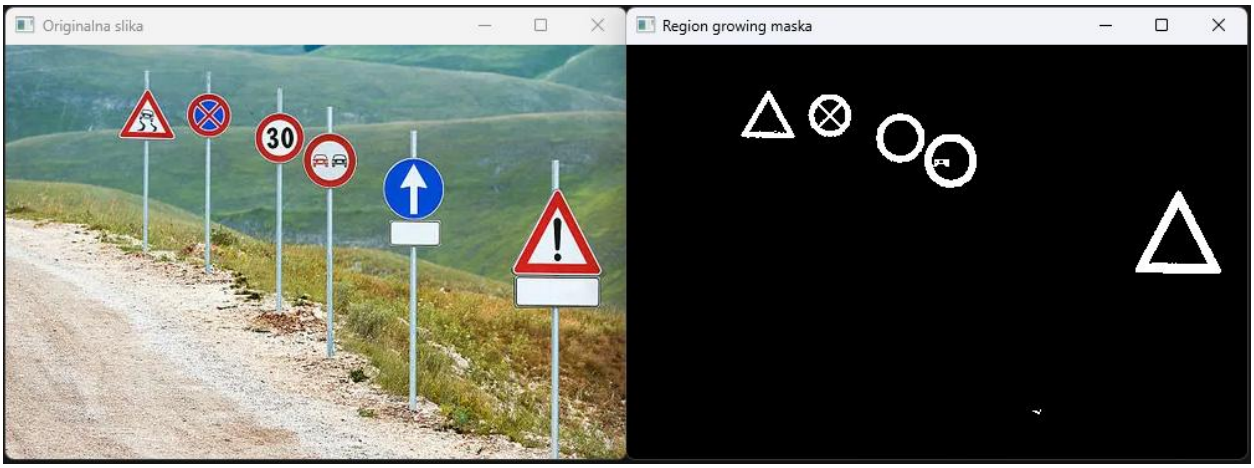
5. Rezultati sistema za prepoznavanje znakova

U okviru ovog poglavlja biće predstavljeni primeri rezultata svakog od delova sistema pojedinačno i njihove analize, koje su njihove mane, postojanost mogućih problema, nakon čega će biti prokomentarisan i rezultat sistema u celosti i biće diskusije o prednostima i ograničenjima samog sistema.

5.1 Rezultati segmentacije po boji

Segmentacija po boji je prva faza u procesu detekcije samih znakova i njen zadatak je da izdvoji sve regione na slici koji pripadaju odgovarajućoj boji znakova, što je u ovom slučaju crvena boja. Rezultat ove faze predstavlja ulaza u fazu analize oblika, pa i samim tim ova faza ne mora biti u potpunosti savršena, ali je potrebno da je moguće izdvojiti regione koje sadrže konture posmatranih saobraćajnih znakova.

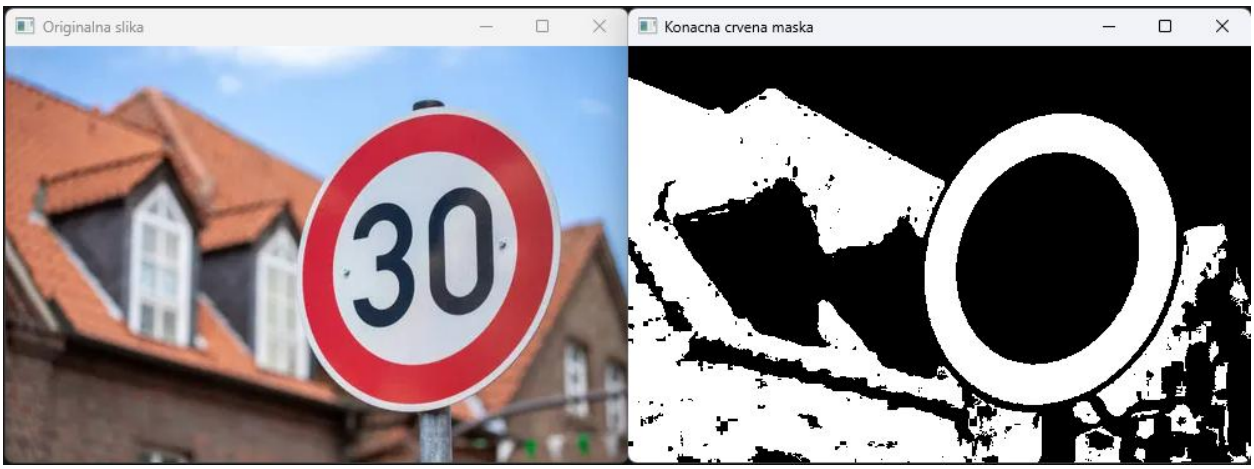
Na slici 5.1 prikazan je primer rezultata ove faze na slici koja sadrži veći broj znakova, koji ne moraju nužno pripadati ciljnim klasama za prepoznavanje implementiranog sistema.



Slika 5.1 Primer rezultata segmentacije po boji za veći broj različitih znakova

Sa leve strane prikazana je originalna slika, dok sa desne binarna maska koja se dobija kao rezultat faze segmentacije po boji na kojoj su belim pikselima označeni pikseli koji zadovoljavaju uslov segmentacije po boji. Na ovom primeru vidi se da se izdvajaju i znakovi koji nisu od interesa za prepoznavanje implementiranog sistema, ali oni se u kasnijim fazama odbacuju.

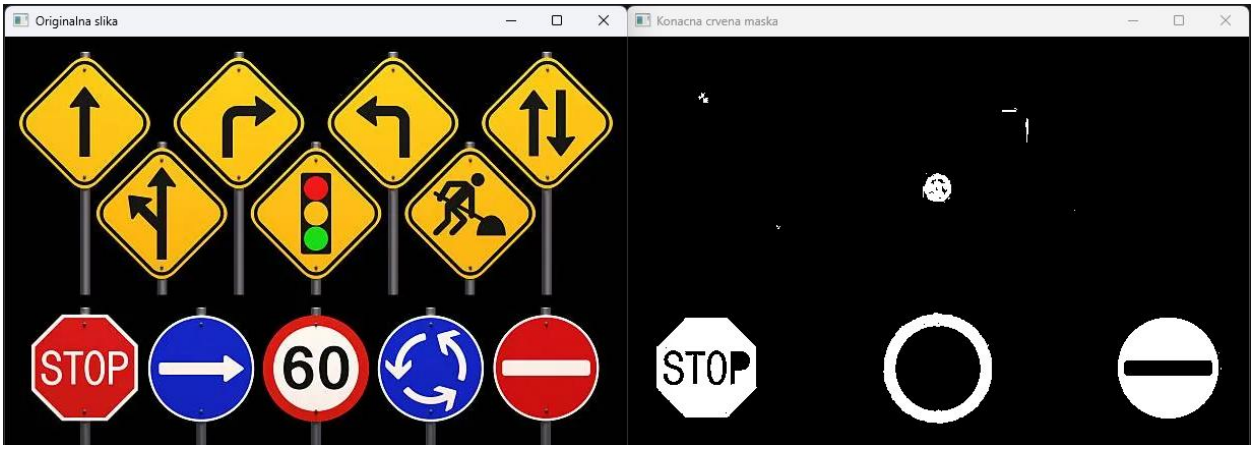
Na slici 5.2 dat je primer rezultata segmentacije po boji na slici koja sadrži saobraćajni znak i druge objekte crvene boje koji se mogu detektovati tokom ove faze.



Slika 5.2 Primer rezultata segmentacije po boji na slici sa drugim objektima crvene boje

Na ovoj slici nalaze se i krovovi kuća čiji pikseli takođe ispunjavaju uslov segmentacije po boji, što je i korektno. Ovi regioni se kasnije u toku faze analize oblika odbacuju jer ne ispunjavaju uslove geometrijskih karakteristika ciljnih znakova za prepoznavanje.

Na slici 5.3 dat je primer rezultata segmentacije po boji na slici koja pored saobraćajnih znakova sadrži i znak za semafor čije crveno svetlo može takođe predstavljati kandidat za potencijalni crveni znak prilikom klasifikacije.



Slika 5.3 Primer rezultata segmentacije po boji na slici koja sadrži crveni krug koji ne predstavlja saobraćajni znak

Vidi se da crveno svetlo znaka za semafor odgovara i koloristićkim i geometrijskim karakteristika saobraćajnih znakova od interesa za prepoznavanje, ali ovaj kandidat se može eliminisati tokom faze klasifikacije konvolutivne neuronske mreže.

Jedna od stvari koju je potrebno naglasiti da su pragovi za uslove segmentacije po boji konkretno izabrani za ovu implementaciju sistema, odnosno ukoliko bi slika sadržala znak koji se nalazi u mraku ili na prevelikom svetlu on ne bi mogao proći ovu fazu. U tim slučajevima je potrebno ili promeniti pragove ili primeniti neke druge tehnike kompjuterske vizije kako bi se to ispravilo.

Primer slike znaka koji implementirani sistem ne može da prepozna jer se znak nalazi u mraku prikazana je na slici 5.4.



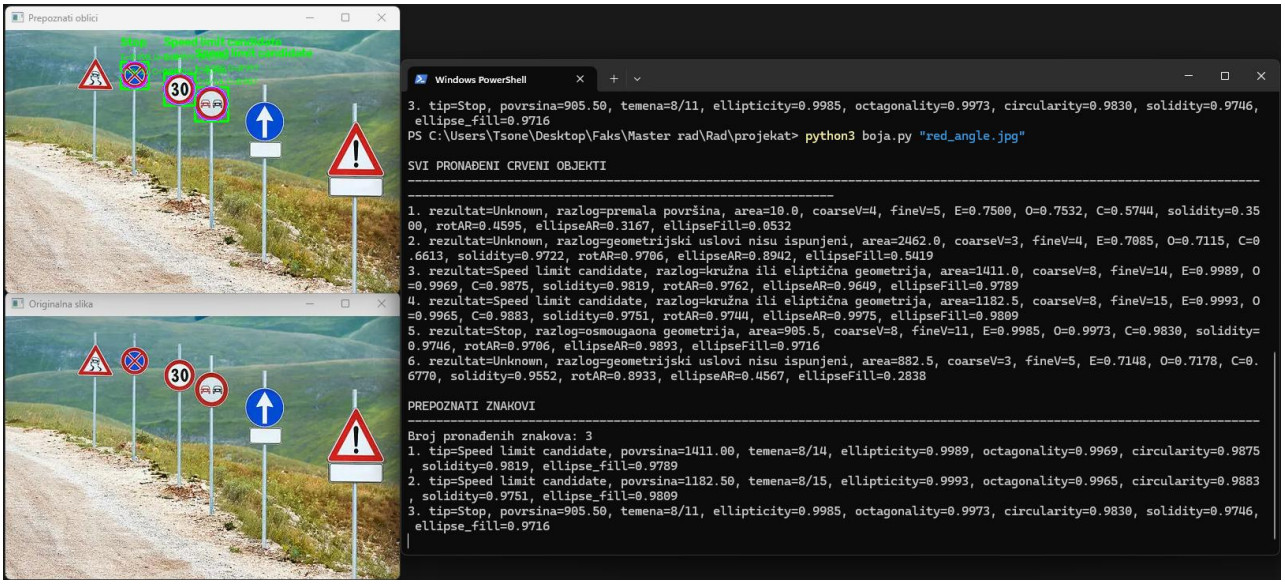
Slika 5.4 Slika znaka koji se nalazi u mraku

Pikseli crvene boje koji pripadaju ovom znaku ne ispunjavaju uslove segmentacije po boji koja je implementirana u okviru ovog sistema, pa samim tim binarnu masku koja se dobija kao rezultat ove faze čine isključivo crni pikseli i njena obrada u daljim fazama postaje besmislena.

5.2 Rezultati analize oblika

Za potrebe prikaza rezultata faze analize oblika koristi se verzija sistema iz ranijih faza jer ona uključuje prikaz detekcije kandidata saobraćajnih znakova na originalnoj slici kao i u terminalu.

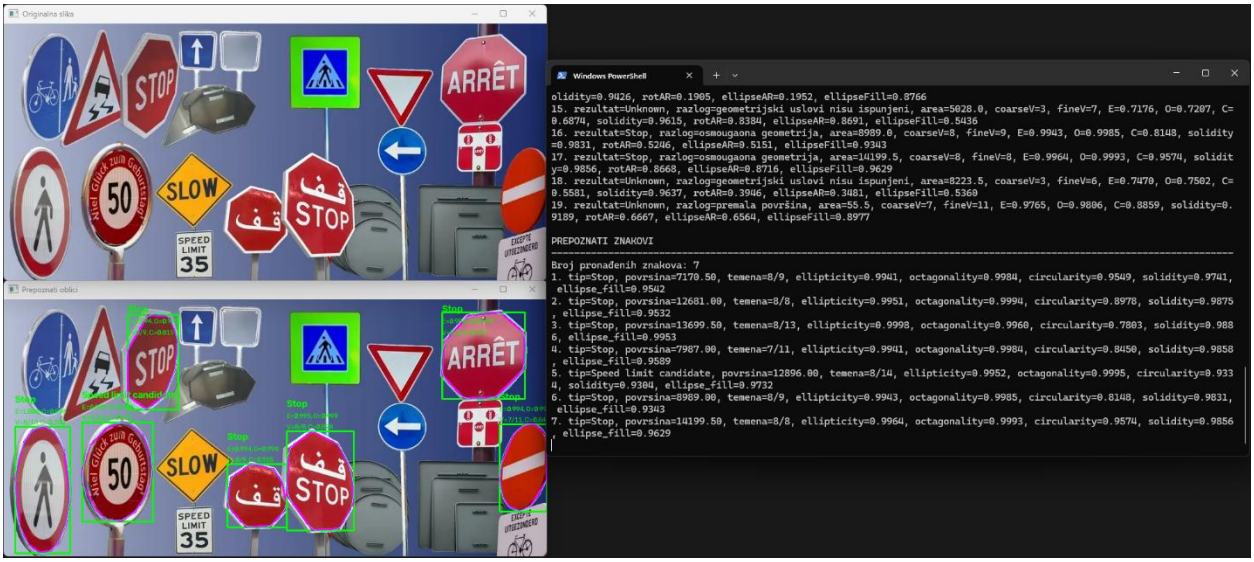
Na slici 4.5 prikazan je rezultat nakon analize oblika jednog od primera iz prethodnog poglavlja.



Slika 5.5 Primer rezultata analize oblika za veći broj znakova

Sa slike može se videti jasna razlika između geometrijskih karakteristika kandidata koji odgovaraju saobraćajnim znakovima od interesa i onih kandidata koji se odbacuju, odnosno onih koji ne ispunjavaju uslove analize oblika. Iz ovog konkretnog primera vidi se da je segmentaciju po boji prošlo šest kandidata. Od tih šest kandidata pet su crveni kružni i trougaoni znakovi, dok poslednji predstavlja mali crveni region na donjoj polovini slike koji se može uočiti na slici 5.1. Ovaj mali region se odmah odbacuje jer je veoma male površine. Nakon toga vidimo da na osnovu geometrijskih karakteristika odbacuju i dva trougaona crvena znaka. Ovde se može uočiti jedna mala mana ove faze, a to je da je jedan od kružnih znakova detektovan kao znak “STOP”. S obzirom da su geometrijske karakteristike znakova ograničenja brzine i znaka “STOP” jako slične, zbog ugla kamere, veličine, pozicije i drugih razloga može doći do mešanja ove dve klase znakova. To i nije od prevelikog značaja za ovaj konkretan sistem jer dalje neuronska mreža može razaznati te znakove međusobno, pa se samim tim ovo i ne uzima kao mana sistema koju je potrebno ispraviti.

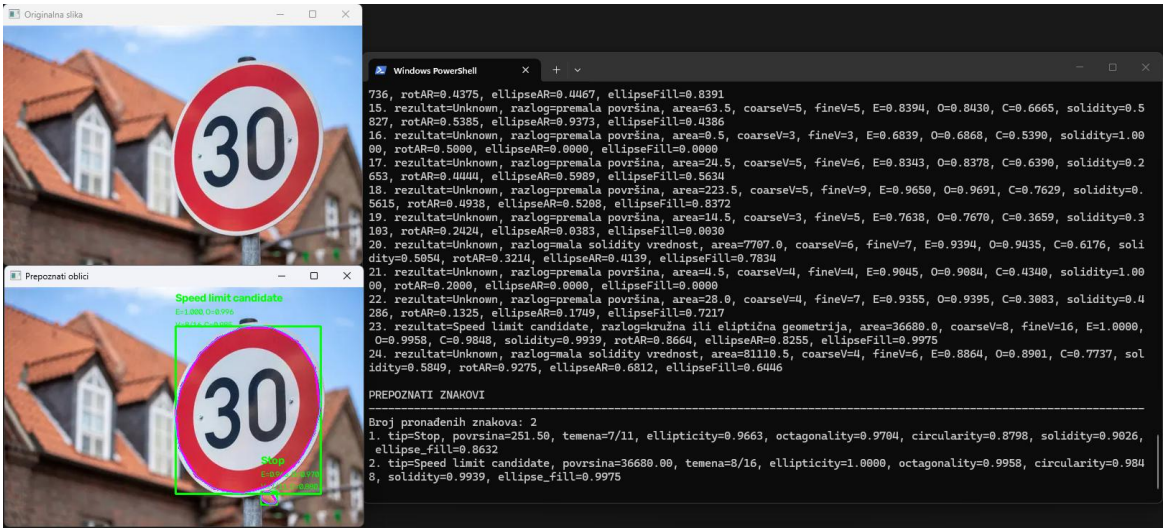
Na slici 5.6 prikazana je karikatura na kojoj je dat velik broj različitih saobraćajnih znakova.



Slika 5.6 Karikatura saobraćajnih znakova

Ovakva slika se nikada neće naći u realnosti, ali je dobra za testiranje procesa segmentacije po boji i analize oblike. Vidi se da je nakon segmentacije po boji dobijeno 19 kandidata potencijalnih znakova. Većina tih kandidata čine manji crveni regioni koji su odbačeni na početku procesa analize oblika. I na ovoj slici se vidi da je par kružnih znakova detektovano kao znakovi “STOP”. Odbačeni su svi oni znakovi koji svojim geometrijskim karakteristikama ne odgovaraju znaku “STOP” i znakovima ograničenja brzine.

Na slici 5.7 dat je još jedan primer rezultata nakon analize oblika znaka prikazanog u prethodnom poglavlju.



Slika 5.7 Primer rezultata nakon analize oblika za jedan znak na slici

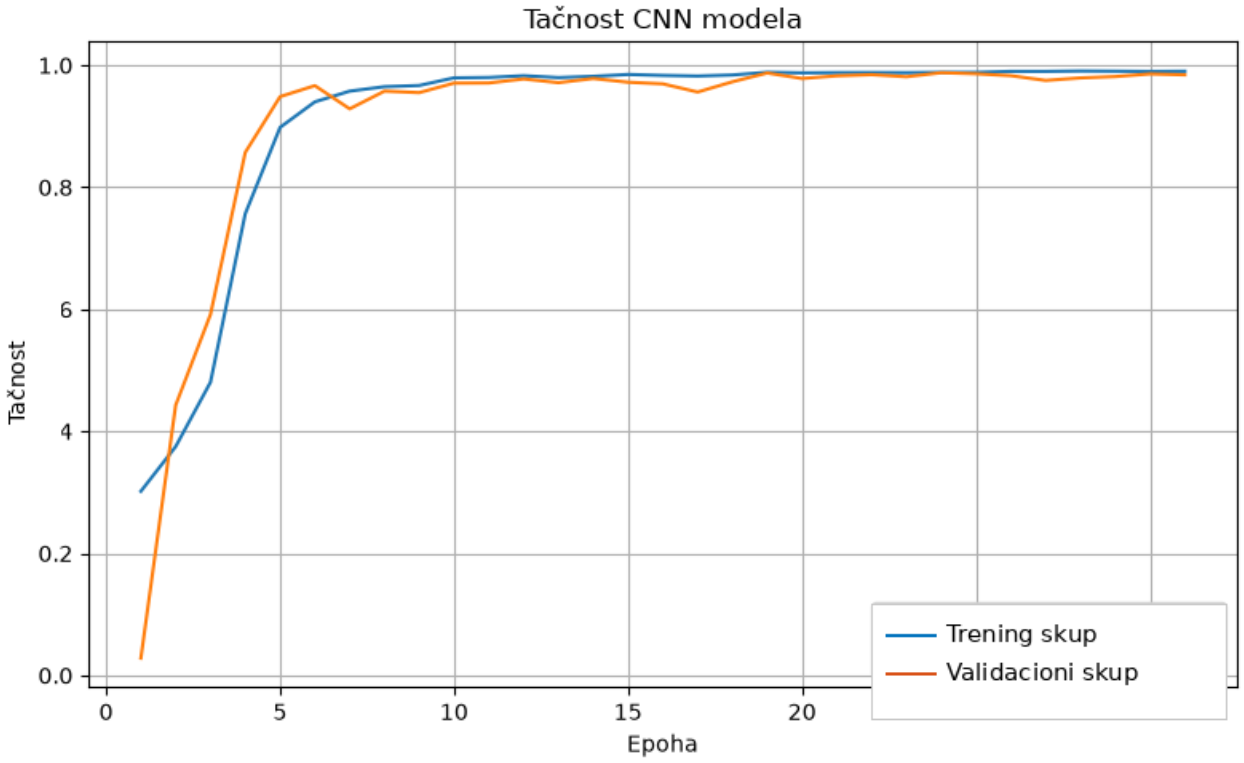
Na ovom primeru se vidi da se na slici nalazi jedan znak a da se nakon segmentacije po boji dobija 24 kandidata. U ovom slučaju analiza oblika radi jako dobar posao tako što se svi crveni regioni koji pripadaju drugim objektima odbacuju. Ovim se smanjuje jako velik broj kandidata koji bi se inače prosledili neuronskoj mreži, što dodatno poboljšava efikasnost sistema.

5.3 Rezultati obučavanja konvolutivne neuronske mreže

Nakon pripreme podataka za obučavanje i kreiranja arhitekture konvolutivne neuronske mreže, izvršeno je njeno obučavanje. Podaci za obučavanje podeljeni su na 70% korišćenih za trening i 30% korišćenih za validaciju. U toku procesa obučavanja praćene su vrednosti tačnosti i funkcije gubitka i na trening i na validacionom skupu.

Maksimalan broj epoha postavljen je na 50. Međutim došlo je do ranog zaustavljanja modela i obučavanje se završilo nakon 31 epohe. Ovim je izbegnuto bespotrebno dalje obučavanje jer nakon 31. epohe poboljšanja rezultata na validacionom skupu više nisu bila dovoljno značajna.

Na slici 5.8 prikazan je grafik promene tačnosti modela na trening i test skupu tokom procesa obučavanja.



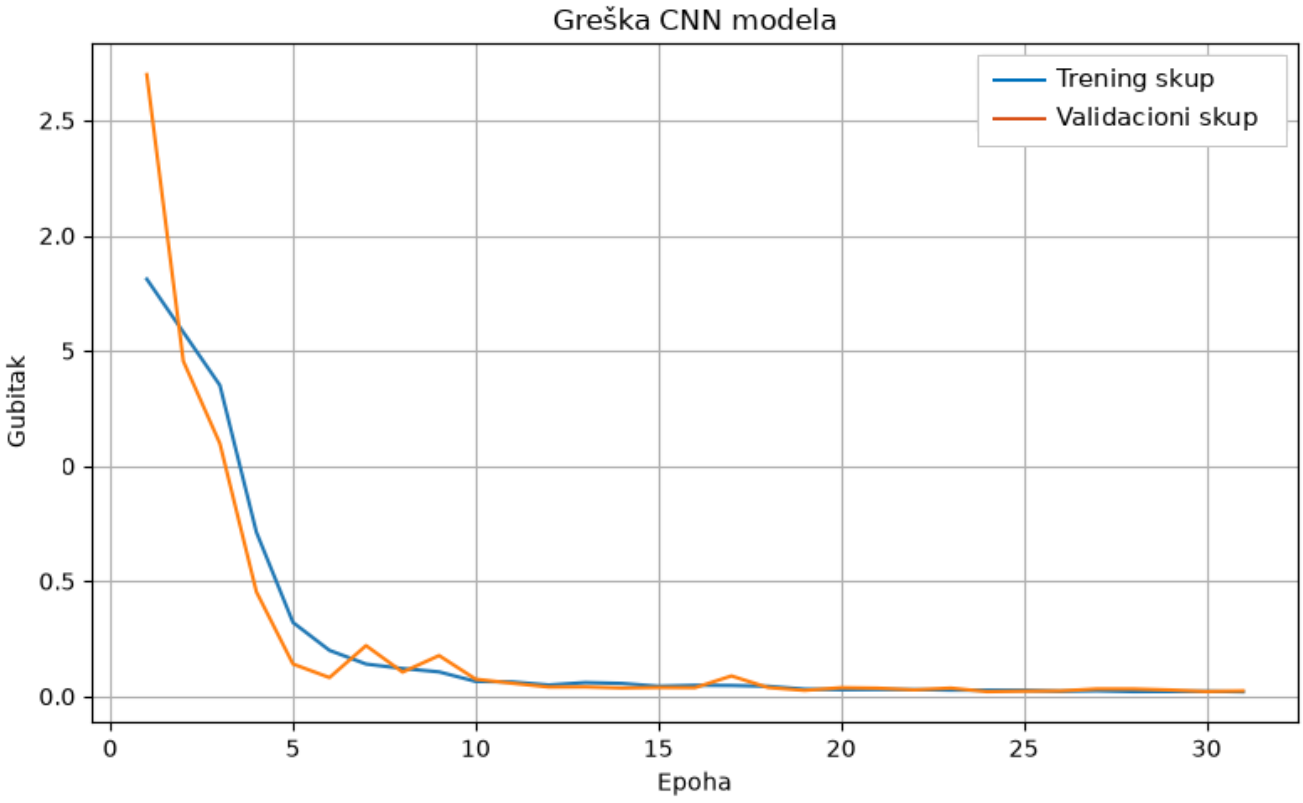
Slika 5.8 Grafik promene tačnosti modela na trening i validacionom skupu tokom obučavanja

Sa grafika može se uočiti da tačnost modela značajno raste tokom prvih par epoha. Najizraženiji rast tačnosti javlja se u prvih pet epoha, nakon čega rast postaje postepeniji, a oko desete epohe tačnost na trening skupu i na validacionom skupu dostiže vrednosti oko 97%-98%, gde nakon toga u ostatku procesa obučavanja ova vrednost kreće da se stabilizuje uz male oscilacije.

Na kraju procesa obučavanja vidi se da vrednost tačnosti dostiže vrednost između 98% i 99%. Jako je značajno da se vrednosti krivih na trening skupu i na validacionom skupu poklapaju.

Takođe vidi se pojava da na pojedinim epohama tačnost na validacionom skupu čak bude veća nego ona na trening skupu. Ovakvo ponašanje nije neočekivano jer se tokom obučavanja nad trening podacima vrši augmentacija i *Dropout*, čime se namerno otežava obučavanje mreže. Vrednost tačnosti na validacionom skupu je veća u nekim epohama zato što se nad podacima za validaciju ne izvršavaju nasumična augmentacija i *Dropout*.

Na slici 5.9 prikazan je grafik promene funkcije gubitka modela na trening i validacionom skupu tokom procesa obučavanja.



Slika 5.9 Grafik promene gubitka modela na trening i validacionom skupu tokom obučavanja

Sa grafika vidi se da se funkcija gubitka ponaša u skladu sa promenom tačnosti, što znači da su vrednosti gubitka najveće u prvih par epoha treniranja, a da veoma brzo opadaju u kasnijim epohama.

Vidi se da je vrednost gubitka na početku na trening skupu oko 1.8, a na validacionom oko 2.7. Već nakon pet do šest epoha ova vrednost se drastično smanjuje, a nakon desete epohe vrednosti gubitka na oba skupa postaju jako bliske nuli i dalje se stabilizuju u ostatku procesa obučavanja.

Na osnovu ovih grafika zajedno, može se zaključiti da je najveći deo učenja ostvaren tokom prvih desetak epoha, jer u tokom njih vrednost tačnosti naglo raste a vrednost funkcije gubitka istovremeno opada. Nakon toga model ulazi u fazu stabilnijeg učenja tako da se nadalje ostvaruju samo mala poboljšanja. Vrednost tačnosti ostaje visoka, dok se vrednost gubitka zadržava na jako niskim nivoima.

Još jedan važan rezultat je i odnos krivih na trening i validacionom skupu. Jedan od jasnih znakova pojave preprilagođavanja je pojava da vrednost tačnosti raste na trening skupu, a istovremeno opada na validacionom skupu. Ovaj slučaj ne važi za model obučen u okviru ovog rada jer se sa grafika vidi da su vrednosti tačnosti i funkcije gubitka jako bliske tokom većeg dela procesa obučavanja. Odnosno ne postoje jasni pokazatelji koji ukazuju na pojavu prekomernog preprilagođavanja modela.

Stabilnosti procesa obučavanja sistema jako doprinose augmentacija podataka, *Dropout*, normalizacija paketića podataka kao i mehanizmi za kontrolu procesa obučavanja, pre svega rano zaustavljanje i smanjenje koeficijenta učenja pri dostizanju platoa.

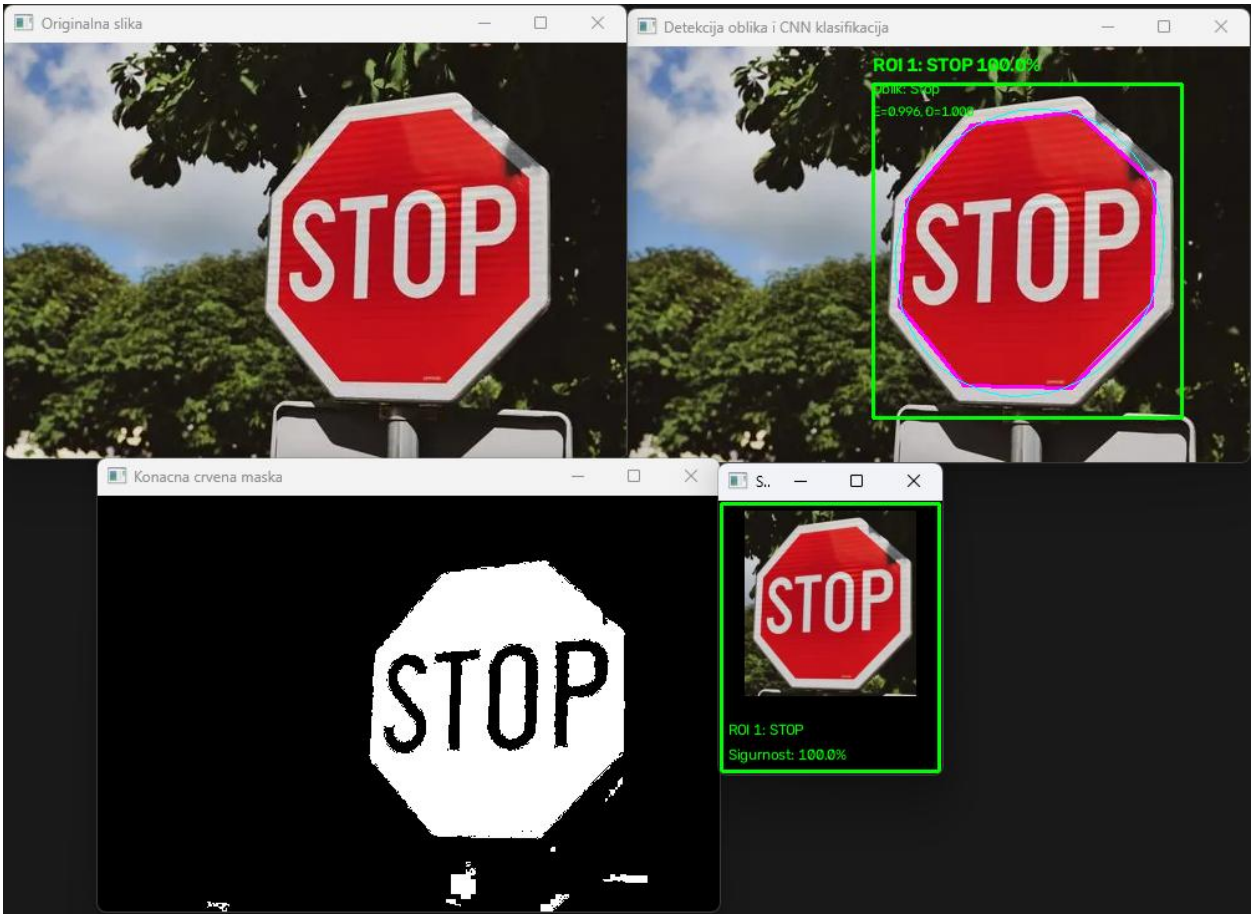
5.4 Rezultati čitavog sistema

Čitav sistem se sastoji iz više delova: segmentacije po boji, analize oblika i konvolutivne neuronske mreže. Ovo znači da uspešnost čitavog sistema zavisi od uspešnosti svakog dela pojedinačno. Odnosno može se reći da je znak prepoznat ukoliko uspešno prođe kroz sve faze sistema. Ukoliko znak nije uspešno izdvojen segmentacijom, to znači da neće uopšte biti prosleđen analizi oblika. Isto tako, znak koji ne zadovoljava uslove geometrijskih karakteristika neće biti dalje prosleđen neuronskoj mreži.

Detekcija se može pojednostaviti uslovom:

$$D = D_{boja} \wedge D_{oblik} \wedge (CNN \geq 0.98)$$

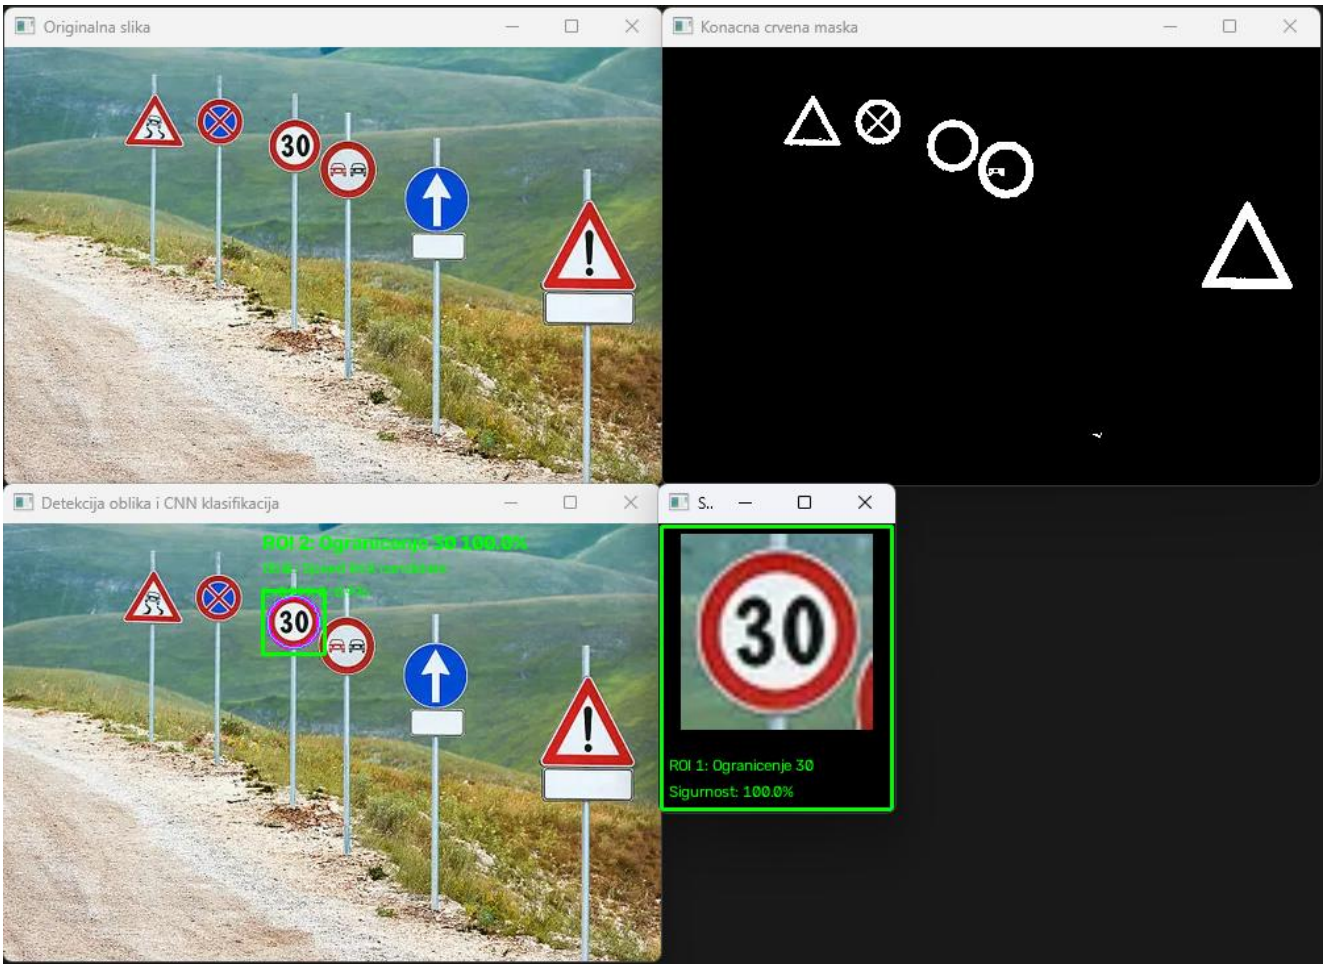
Na slici 5.10 dat je primer rezultata sistema za prepoznavanje znaka „STOP“.



Slika 5.10 Prepoznavanje znaka „STOP“

Sa slike vidi se da u okviru faze segmentacije znaka stop sa ove slike postoje manji regioni crvene boje pri dnu slike koji predstavljaju potencijalne kandidate znakova pre analize oblika. Ovi kandidati se odbacuju još tokom faze analize oblika, gde kao jedini kandidat ostaje stvarni znak stop. Nakon toga mreža korektno prepoznaje znak stop i on se obeležava na slici. Iz ovog primera se vidi da se tokom faze analize oblika vrši jako bitno odbacivanje kandidata koji nikako ne bi prošli kao saobraćajni znakovi, dok se segmentacijom po boji odbacuje čitava pozadina koja ne odgovara posmatranom znaku.

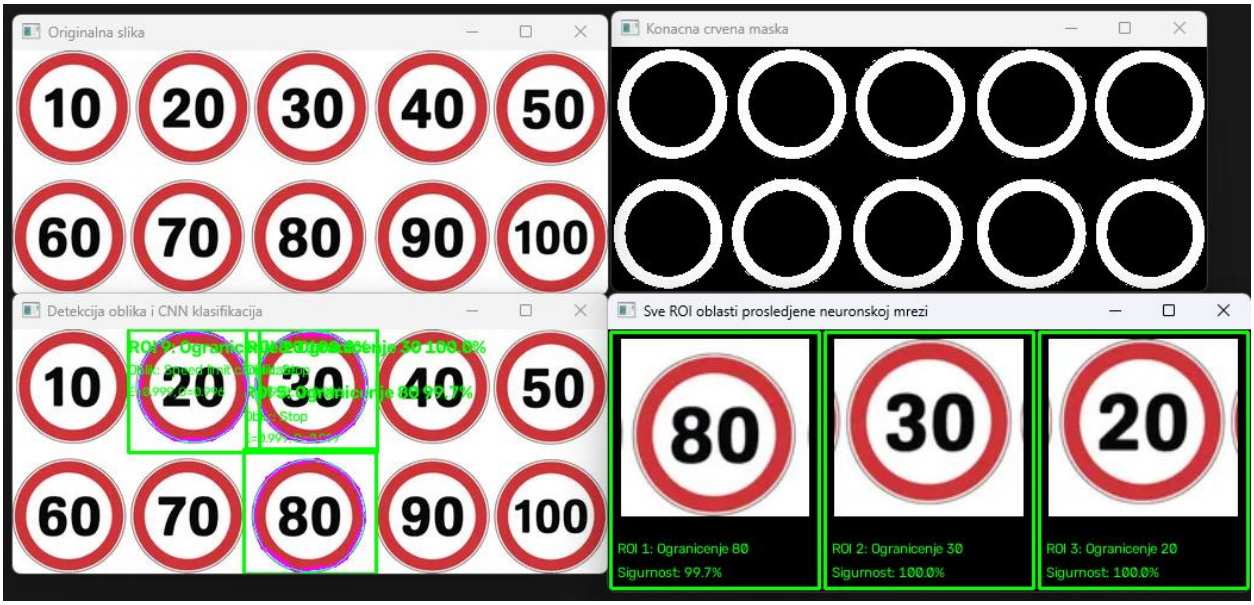
Na slici 5.11 dat je konačan rezultat jednog od primera iz prethodnog poglavlja.



Slika 5.11 Prepoznavanje znaka 30

Sa slike se vidi da je korektno prepoznat znak ograničenja brzine za 30km/h. Vidi se da su trougaoni znakovi odbačeni u fazi analize oblika, dok su tu fazu prošli ostali kružni kandidati crvene boje. Na kraju neuronska mreža dala je verovatnoće pripadnosti odgovarajućoj klasi za sve kandidate saobraćajnih znakova, od kojih je finalni prag sigurnosti jedino ispunio znak ograničenja brzine. Takođe potrebno je naglasiti da mreža može dati verovatnoće pripadnosti samo za devet klasa koje su uključene u implementaciji ovog sistema, što znači da je svakom od kružnih kandidata crvene boje koji zapravo nisu znakovi ograničenja brzine dodeljena je verovatnoća pripadnosti jednoj od tih devet klasa, ali oni se nisu uključili u finalno prepoznavanje jer njihove sigurnosti ne zadovoljavaju prag sigurnosti klasifikacije.

Na slici 5.12 nalazi se primer prepoznavanja znakova sa slike koja sadrži velik broj različitih znakova ograničenja brzine.



Slika 5.12 Prepoznavanje znakova sa slike koja sadrži velik broj različitih saobraćajnih znakova

Iako se na slici nalazi velik broj klasa saobraćajnih znakova za ograničenje brzine za koje je ovaj sistem implementiran da prepozna, on prepoznaje samo tri. Svaki od ovih znakova prolazi fazu segmentacije po boji i fazu analize oblika, što govori o tome da nemogućnost konačnog prepoznavanja znakova koji bi trebali biti prepoznati potiče od neuronske mreže. Jedan od mogućih razloga za ovo je nedovoljno raznovrsnih podataka za trening, pa samim tim mreža nije bila u mogućnosti da tačno prepozna neke znakove jer se na primer pozadina njihovih regiona od interesa ne poklapa sa pozadinama znakova iz trening skupa podataka, pa time mreža ne može prepoznati neke karakteristike koje je naučila. Jedno moguće rešenje ovog problema je da se proširi skup podataka za trening sa slikama znakova sa različitijim pozadinama. Ali s obzirom da je korišćen skup podataka za izradu ovog rada otvorenog tipa to nije urađeno jer zahteva više dodatnih napora.

6. Zaključak

Na osnovu rezultata sistema može se zaključiti da kombinovanje metoda računarskog vida i metoda mašinskog učenja predstavlja pogodan pristup za izradu robusnog sistema za prepoznavanje odabranih saobraćajnih znakova. Iz rezultata sistema takođe se vidi da informacije o boji i geometrijskim karakteristikama čine jako dobru osnovu za izdvajanje pojedinačnih saobraćajnih znakova se celokupne slike koja može pored većeg broja znakova sadržati i druge slične objekte, dok konvolutivna neuronska mreža predstavlja korektan izbor za razlikovanje konkretnih klasa znakova sličnih karakteristika.

Rezultati obučavanja neuronske mreže pokazali su visoku tačnost korišćenjem trening i validacionog skupa, pri čemu nakon stabilizacije tačnosti ona na kraju ima vrednost približno 98%-99%. Bliske krive ne ukazuju na izraženo preprilagođavanje na posmatranoj podeli odataka. Ipak, rezultati samog rada samog modela sami po sebi ne garantuju da će takvi biti i rezultati celokupnog sistema u realnim uslovima.

Jedna od značajnih prednosti razvijenog sistema predstavlja mogućnost postepenog eliminisanja kandidata saobraćajnih znakova prolaskom kroz faze sistema. Konačna odluka se ne zasniva samo na jednom svojstvu objekta, već kombinacijom koloristčkih i geometrijskih karakteristika. Pored toga, korišćenje praga sigurnosti klasifikacije omogućava odbacivanje onih kandidata za koje mreža nije dovoljno sigurna i samim tim se smanjuje još veći broj nepouzdanih kandidata.

Na osnovu rezultata sistema može zaključiti da postoje i određena ograničenja ovakvog sistema. Naime, uspešnost sistema u značajnoj meri zavisi od kvaliteta ulazne slike, kao i od uslova u kojima je ona slikana. Promene osvetljenja mogu otežati korektno prepoznavanje boja, dok veliki ugao posmatranja, delimična zaklonjenost i mala veličina znaka mogu otežati prepoznavanje oblika. Pokazano je da greška detekcije u ranijoj fazi dovodi do toga da se objekat i ne prosleđuje neuronskoj mreži, iako bi ona potencijalno korektno prepoznala znak. Postavljanje visokog praga sigurnosti klasifikacije smanjuje broj nesigurnih predikcija, ali kao posledica se može javiti odbacivanje korektno klasifikovanih znakova sa nižom sigurnosti.

Zbog ovakvih nedostataka razvijen sistem predstavlja osnovu koja se dalje može unaprediti. Prvo pogodno unapređenje sistema bilo bi dodavanje još kategorija saobraćajnih znakova pored znaka „STOP“ i znakova ograničenja brzine. Da bi se to postiglo potrebno je proširiti skup podataka za obučavanje, kao i prilagoditi faze detekcije tako da u obzir uzimaju i znakove drugih boja i oblika. Dodatno poboljšanje sistema bilo bi proširivanje skupa podataka slikama slikanim u različitim uslovima, odnosno slike slikane iz različitih udaljenosti, različitih uglova posmatranja, u različitim vremenskim uslovima, što bi doprinelo robusnosti sistema. Pored ovoga mogla bi se ostvariti i adaptivno određivanje kriterijuma segmentacije, čime bi se izbegla potreba za unapred definisanim pragovima boje.

Još jedno jako važno unapređenje mogao bi biti prelaz rada sistema prepoznavanja znakova sa slike na prepoznavanje znakova sa videa u realnom vremenu. Ovim bi sistem mogao da obrađuje snimke kamere postavljene na vozilu i kontinuirano detektuje saobraćajne znakove tokom kretanja i dalje te informacije prosleđivao vozaču ili upravljačkom sistemu vozila. Informacije dobijene iz više uzastopnih kadrova bile bi korisne za potvrđivanje detekcije.

Ovakvo unapređenje sistema omogućilo bi njegovu primenu u sistemu za pomoć vozaču. Kamera koja bi bila postavljena na vozilu bi slike koje snimi prosleđivala sistemu, koji bi dalje mogao prepoznati znakove ograničenja brzine i znak „STOP“ i te informacije bi se prikazale vozaču ili bi služile za generisanje neke vrste upozorenja. Takođe daljim unapređenjem moglo bi se postići da se ove informacije povežu sa drugim informacijama u okviru vozila, kao što je to brzina kretanja, što bi se moglo koristiti za automatsko usklađivanje brzine vozila ili nešto slično.

Na osnovu svega što je do sada navedeno može se zaključiti da se kombinovanjem različitih pristupa računarskog vida i mašinskog učenja može realizovati funkcionalan sistem za prepoznavanje saobraćajnih znakova. Dobijeni rezultati ukazuju na to da postoji prostor za dalje unapređenje samog sistema, naročito poboljšanje robusnosti sistema u realnim uslovima proširivanjem broja različitih znakova koje sistem može da prepozna, kao i uvođenje obrade videa u realnom vremenu. Ovim unapređenjem sistem bi predstavljao osnovu za razvijanje rešenja namenjenih praktičnoj primeni u vozilima.

Literatura

[1] Lim, X. R., Lee, C. P., Lim, K. M., Ong, T. S., Alqahtani, A., & Ali, M.

Recent Advances in Traffic Sign Recognition: Approaches and Datasets.

Sensors, 23(10), 4674, 2023.

https://doi.org/10.3390/s23104674

[2] Pravilnik o saobraćajnoj signalizaciji,

"Službeni glasnik Republike Srbije", br. 85/2017, 14/2021 i 21/2024.

[3] Gonzalez, R. C., Woods, R. E. , Digital Image Processing, Fourth Edition. ,

Pearson, 2018.

[4] J. Stallkamp, M. Schlipsing, J. Salmen i C. Igel, "German Traffic Sign Recognition Benchmark (GTSRB)", https://benchmark.ini.rub.de/gtsrb_dataset.html

[5] H. Fleyeh, Traffic and Road Sign Recognition, PhD Dissertation, Dalarna University, 2008.

[6] J. Flusser, T. Suk, "Pattern Recognition by Affine Moment Invariants", *Pattern Recognition*, vol. 26, no. 1, pp. 167–174, 1993.

[7] P. L. Rosin, "Measuring Shape: Ellipticity, Rectangularity, and Triangularity", *Machine Vision and Applications*, vol. 14, pp. 172–184, 2003.

[8] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.

[9] S. Ioffe, C. Szegedy, “Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift,” *Proceedings of the 32nd International Conference on Machine Learning*, vol. 37, pp. 448–456, 2015

[10] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, R. Salakhutdinov, “Dropout: A Simple Way to Prevent Neural Networks from Overfitting,” *Journal of Machine Learning Research*, vol. 15, pp. 1929–1958, 2014.

[11] D. P. Kingma, J. Ba, “Adam: A Method for Stochastic Optimization,” *International Conference on Learning Representations (ICLR)*, 2015.

[12] Python Software Foundation, The Python Tutorial, Python Documentation.

[13] OpenCV, *OpenCV Documentation*, Open Source Computer Vision Library.

[14] TensorFlow, *TensorFlow Basics*, TensorFlow Documentation, Google.

[15] OpenCV, *Structural Analysis and Shape Descriptors*, OpenCV Documentation.

Izvor slika

3.1 https://www.analyticssteps.com/blogs/common-architectures-convolution-neural-networks